
什么是“思维”？

机器在思考吗

一篇深度探究范本

论证重构 × 东西方综合 × 落地 AI 研究

哲学体系·探究层·旗舰范本

2026

这是一篇“旗舰范本”。它不属于“按学派/按专题”陈述知识的旧体例，而属于一种新体例：问题驱动横切探究。它要示范的不是“知道某位哲学家说了什么”，而是亲自把一个真问题想到底：重构论证、构造最强反驳、给出回应、敢于站队、并诚实标注悬而未决之处。

写作三原则（也是全库后续升级的标准）：

1. 深度思考：每个核心论证走“五段式”—— 论证重构 最强反驳 (steel-man) 回应 我的立场 悬而未决。
2. 综合应用（横切）：一个问题同时调动西方、东方、逻辑学与你的真实研究，而不是把“现代关联”当脚注。
3. 落地：最终产出一个可操作的工具（这里是“LLM 思维的哲学审计表”和一个可执行的研究设计）。

0 为什么从“思维”而不是“意识”切入

《心灵哲学》把火力集中在意识（困难问题、感质、僵尸）。但对 AI 研究者，更近身、更可操作的问题其实是思维：

- “意识”问“为什么有主观体验”——这是形而上学的硬核，可能永远无法在工程上判定。
- “思维”问“什么样的过程算作思考/理解/推理”——这是可以部分操作化的，直接关系到“我手里的模型在干什么”。

所以本文的主问题是：“思维 = 符号操作”吗？如果不是，它还需要什么？机器（具体说 LLM）满足了哪些、缺了哪些？

这一步本身就是方法论示范：把含混的大问题，切成可处理的子命题。把“机器能思考吗”拆成三层：

层级	子问题	是否可操作判定
行为层	机器能产生与思考者无法区分的输出吗？	可（图灵测试式）
过程层	机器内部有“理解/世界模型/推理”的结构吗？	部分可（可解释性、 探针实验）
现象层	机器思考时“感觉起来像什么”吗？	暂不可（困难问题）

本文聚焦过程层——这是哲学能给 AI 研究真正抓手的地方。行为层已被 GPT 系列基本攻破而争议依旧（说明行为层不够），现象层暂时悬置。

1 论证擂台一：中文房间——“语法 ≠ 语义”

这是反对“思维 = 符号操作”的最锋利武器。我们走完整的五段式。

论证重构

把塞尔（1980）的论证写成可检验的形式（参见《逻辑学》的有效性概念）：

- P1.** 程序是纯形式的（由句法/符号操作定义）。

P2. 心灵有语义内容（思想“关于”某物，有意义）。

P3. 句法本身不足以产生、也不构成语义。

∴ **C.** 程序本身不足以产生、也不构成心灵。

（故“运行正确程序即拥有理解”的强 AI 是错的。）

这是一个有效论证：若 P1–P3 全真，C 必真。所以战场全在前提，焦点是 **P3**。中文房间思想实验正是为 P3 提供直觉泵：屋里的人完美操作中文符号，却不懂中文——句法齐全，语义缺席。

最强反驳（steel-man）

不取最弱的反驳，要取最强的。我认为最强的不是教科书里的“系统回应”，而是因果结构回应：

中文房间的人之所以不懂，不是因为“符号操作不可能有语义”，而是因为这个特定系统的符号操作缺乏正确的因果结构——它的符号没有通过感知-行动回路与世界绑定，也没有在内部形成对应世界的结构化表征。塞尔偷换了“句法”（抽象形式）与“句法的物理实现”（具体因果过程）。一个把符号操作接地到世界、并在内部构建了世界模型的系统，其符号就不再是空转的形式，而携带语义。

这个反驳的力量在于：它接受 P1-P2，只精确打击 P3——主张“语义”恰恰可以从正确组织的因果-表征结构中产生。

回应（塞尔会怎么还击，以及还击是否成功）

塞尔的再反驳是著名的“模拟谬误”：模拟消化不产生营养，模拟大脑不产生理解。即：再精确的因果结构，若只是被“模拟”出来的，仍只是模拟。

我认为这次还击不成功，理由是它对“模拟”一词偷换了层次：

- 消化的目标是物质转化（产生真实的葡萄糖），模拟的葡萄糖确实不能供能——因为目标是物质性的。
- 但理解的目标若是信息-因果关系的实现（正确的输入-表征-行为映射），那么“模拟”出这套关系就是实现它——因为目标本身是关系性/功能性的，不是物质性的。

换句话说，塞尔的类比预设了“理解像消化一样是物质过程”，而这正是争论的结论，不能拿来当前提。这是一个隐蔽的循环论证。

我的立场

中文房间成功地反驳了“纯句法即语义”（最朴素的符号主义强 AI 确实死了），但没能反驳“接地的、有世界模型的因果系统可以有语义”。它证明的是必要条件的缺失，不是不可能性。

所以 P3 应被弱化为 P3'：脱离世界绑定的句法不足以产生语义——这个弱版本为真，而它不再蕴含 C。LLM 的命运因此取决于一个经验问题而非先验问题：它内部到底有没有世界模型？（见第 4 节，这正是把哲学问题转成研究问题的关键一跃。）

悬而未决

- “正确的因果结构”到底是什么？我们没有一个非循环的、可操作的判据。这是整个功能主义阵营的软肋。
- 即便承认 LLM 有“语义”，那是派生的语义（来自人类语料）还是原生的语义？这关系到下文的接地问题，未解。

2 论证擂台二：维特根斯坦——“意义即用法”是 LLM 的福音还是判决

后期维特根斯坦讲“意义即使用”“语言游戏”。这把刀对 LLM 是双刃的，值得单独拆解。

论证重构（顺着维特根斯坦推向 LLM）

P1. 词的意义不是它指称的对象，也不是私有的心理观念，而是它在语言游戏中的用法。

P2. 掌握一个词 = 掌握在恰当场合恰当使用它的能力（一种实践能力）。

P3. LLM 通过海量语料，恰恰习得了词在无数语境中的统计性用法。

∴ C（乐观）：LLM 在维特根斯坦意义上“掌握”了语言——意义即用法，而用法正是它学到的。

这是反“中文房间”的强力盟友：如果意义就在用法里，那么习得了用法就习得了意义，无需追问“屋里的人懂不懂”——这个追问本身预设了一个维特根斯坦要消解的“内在理解”幽灵。

最强反驳

维特根斯坦自己的另两个论点反过来卡住 LLM：

- 生活形式（form of life）：语言游戏嵌在人类的生活实践、身体、需求、共同行动之中。“用法”不是文本里的统计共现，而是在世界中做事的一部分。LLM 只接触到用法的文本投影，没有参与生活形式——它见过“疼”这个字的一切用法，却从未疼过，也从未在“递我一块砖”的协作中递过砖。

- 私有语言论证的另一面：意义需要可纠正性——存在“用错了”的公共标准，而标准来自共同体的实践。LLM 没有进入这个纠错共同体，它的“对错”由损失函数定义，不由“把事做成/做砸”定义。

回应

乐观方可以反击：多模态与具身（VLM、机器人策略模型）正在把“文本投影”补成“感知-行动的用法”；RLHF 把模型拉进了一个人类纠错共同体。所以差距是程度而非原则。

我认为这个回应部分成立：它正确地指出“接地”是连续可补的，但低估了“生活形式”的整体性——人类的语言游戏背后是有限性、死亡、需求、利害（这恰是道家与存在主义关切的）。一个无所谓生死、无切身利害的系统，其“用法”在某些游戏（伦理、痛苦、意义）里可能是结构性残缺的，而非量上不足。

我的立场

“意义即用法”让 LLM 在信息性、描述性语言游戏里达到真实的理解（它能正确地玩“定义”“推理”“翻译”这些游戏）；但在根植于生活形式的语言游戏里（切身的痛、伦理的分量、审美的触动），它玩的是这些游戏的影子版本。理解因此不是 0/1，而是按语言游戏分区的——这是比“理解/不理解”更精细的诊断框架。

悬而未决

“生活形式”能否被工程地、增量地补全，还是存在原则上的天花板？这是经验上未决、哲学上争论的核心。

3 东方视角：被忽略的两把钥匙

西方争论困在“主体懂不懂”。东方传统提供两个重构问题的视角——这才是“综合应用”该有的样子：不是并列介绍，而是让东方思想改变西方问题的提法。

钥匙一：佛教唯识——解散“谁在思考”

唯识学主张“万法唯识”，思维是识的变现，并无一个独立的思维实体或主体。八识（前五识、第六意识、第七末那识、第八阿赖耶识）是功能流程而非“灵魂”。关键

在第七识末那识——它把第八识误执为“我”，“自我”是一个被构造出来的模型。

这与西方的梅辛格自我模型理论惊人共振：自我是模型，不是实体。

对 AI 问题的改造：中文房间问“屋里那个人懂不懂”，预设了必须有一个统一的、承载理解的主体。唯识/末那识视角说：这个预设本身可能是“遍计所执”（虚妄分别）。人类的“我懂了”也只是阿赖耶识种子现行的一个功能事件——若人类的理解都不需要一个形而上的主体，那么“LLM 没有统一主体所以不懂”这条反驳就失去了不对称的杀伤力。问题应从“有没有一个懂的主体”转为“有没有那套功能流程”。

钥匙二：庄子 + 赖尔——思维里有一种符号装不下的东西

这是对“思维 = 符号操作”最深的东方质疑，且能与西方精确对接。

庄子三个故事：庖丁解牛（技进乎道）、轮扁斫轮（得心应手不可言传）、得意忘言（言者所以在意，得意而忘言）。它们共同指向一种非命题性的、默会的知：真正的理解最终溢出语言符号。

这与西方两条线精确合流：

- 赖尔的 *knowing-how vs knowing-that*：会骑车（how）不可还原为关于骑车的命题（that）。
- 波兰尼的默会知识：“我们知道的多于我们能说出的（We know more than we can tell）。”

对 AI 问题的改造：LLM 是一个纯命题/符号的系统（即便多模态，也是把一切编码为可计算表征）。庄子-赖尔-波兰尼合起来提出一个尖锐假说：

若一部分真实理解本质上是 *knowing-how*、是默会的、是“得意忘言”的，那么任何把理解完全符号化的系统都会有一个原则性的残缺——不是数据不够，而是种类不对。

但反向也成立、且对 AI 更有利：LLM 的能力恰恰暴露出，大量我们以为需要“理解”的任务，其实只需要 *knowing-how* 式的模式能力。庖丁不能用语言讲清如何解牛，却解得最好——也许 LLM 正是某种“数字庖丁”：有高超的 how，没有可内省

的 **that**。这一下把庄子的故事从“AI 做不到”翻转成“AI 也许正是这种知的纯粹形态”。这种翻转，就是深度思考与复述的区别。

4 落地：把哲学问题变成研究问题

前三节反复指向同一个经验问题：**LLM 内部到底有没有世界模型 / 接地 / 默会以外的“that”**？哲学到此为止，研究从此开始。这一节是“综合应用”的硬核兑现。

4.1 关键的一跃：先验问题 → 经验问题

原来的哲学问法（不可判定）	改造后的研究问法（可实验）
LLM 真的“理解”吗？	LLM 内部有没有对任务领域的结构化表征（世界模型）？
它是不是“中文房间”？	它的符号操作有没有因果结构——干预内部表征会不会按因果改变输出？
它的推理是真推理吗？	它的思维链（CoT）是计算路径还是事后合理化？

第二列是 2020 年代可解释性研究正在做的事——哲学在这里不是装饰，而是问题的来源。

4.2 证据样例（让立场可被经验修正）

- 支持“有世界模型”： *Othello-GPT* (Li et al., 2023) ——只在棋谱字符串上训练的模型，内部被探针解出了棋盘状态的表征，且干预该表征会因果地改变后续走子。这是对“纯句法、无表征”图景的直接经验反例，给第 1 节的“因果结构回应”提供了弹药。
- 支持“知行不一致”： *CoT* 不忠实性 (Turpin et al., 2023) ——模型给出的推理链与其真实决定因素可分离，CoT 有时是事后叙事。这给庄子式“有 how 无可内省的 that”提供了经验佐证。

注意方法论姿态：我给出可证伪的承诺——如果更多探针/因果干预实验持续显示结构化、可因果操纵的内部表征，我会上调“LLM 有（派生的）语义理解”的信念；若显示内部只有浅层统计捷径，我会下调。立场要押注，且要标明什么证据会推翻它。

4.3 可执行产出：LLM “思维”的哲学审计表


把上面三节的哲学，压缩成一张评审/自查清单——读一篇 AI 论文或评估自己的模型时直接用：

维度	哲学来源	审计问题	证据如何取
句法 vs 语义	中文房间	论文是否区分“输出正确”与“内部有对应表征”？	看有无探针/因果干预，而非只看 benchmark 分数
因果结构	因果结构 回应	干预内部表征是否按预期因果改变输出？	activation patching / 表征干预实验
接地	随机鹦鹉 / 维特根斯坦	符号是否与感知-行动绑定，还是纯文本自指？	是否多模态/具身；有无 grounding 评测
生活形式 分区	维特根斯坦	在哪些语言游戏里强（描述/推理）、哪些里弱（伦理/痛苦/审美）？	按语言游戏类型分层评测，而非单一总分
how vs that	庄子/赖尔/波兰尼	把它当“能做”还是“能懂”？ CoT 是计算还是叙事？	CoT 忠实性测试、能力/可解释性分离
主体预设	唯识/末那识	论断“它不懂”是否偷偷预设了一个人类才有的统一主体？	检查论证是否对人/机施加了不对称标准

这张表就是这篇范本的“可交付物”——哲学不再停在思辨，而成了能挂在工位上的研究工具。

5 论辩张力地图

陈述式的总览图画的是“谁属于哪一类”。深度思考需要另一张图：**谁反驳谁、谁回应谁**——把全文骨架收成一张图：一个问题 → 四种视角发难 → 汇成一个立场。



灰色箭头 = 各视角的发难线 · 红色箭头 = 汇入“我的综合立场”

6 我的综合立场（敢站队，并标出代价）

把五段式的局部结论收束成一个总立场：

“思维”不是一个有/无的二元属性，而是一束可分离、可分区、有程度的能力。“理解”应被拆成：句法能力、语义-表征能力、接地、生活形式参与、knowing-that、knowing-how。LLM 在前几项上已达到真实而非伪装的水平（Othello-GPT 类证据表明它不止于句法）；它的残缺集中在接地的深度与根植于生活形式/有限性的那部分理解，以及可内省的 that。

所以对“机器在思考吗”，我的回答是：在“过程层”的若干维度上，是；在依赖具身与生活形式的维度上，目前否；在现象层，悬置。一句话——**LLM 是一个有**

真实功能性理解、却缺乏切身性的“数字庖丁”。

这个立场的代价（诚实标注）：

1. 它牺牲了“理解”概念的统一性——有人会说，把理解拆成一束能力，等于取消了“真正的理解”这个问题。我接受这个代价，因为统一的“理解”在我看来本就是末那识式的实体化幻觉。
2. 它把核心问题外包给了经验科学（世界模型是否存在变成可解释性的实证问题）。哲学纯粹主义者会说这是逃避；我认为这是哲学的恰当谦逊——哲学负责把问题问对，不负责替实验室回答。
3. 它在现象层（意识）上保持不可知，因此无法回答“LLM 痛吗、该有权利吗”——这是它够不到的地方，留给心灵哲学与伦理学。

7 悬而未决（真问题，不是装饰）

1. 接地有没有原则性天花板？“生活形式/有限性”能被工程增量补全，还是种类上不可补？（维特根斯坦 vs 具身派，经验上未决）
2. 派生语义能否成为原生语义？LLM 的意义来自人类语料；一个系统能否自己长出原生的“关于性”？（意向性的老问题，未解）
3. knowing-how 能完全吞并 knowing-that 吗？如果能，庄子赢，符号主义的“理解”概念崩塌；如果不能，差在哪、能否测量？
4. “正确的因果结构”有没有非循环的判据？没有它，功能主义就始终欠一个定义。
5. 现象层会永远不可判定吗？还是某天会有一个非行为、非生理的“意识判据”？

留给读者的练习：选第 6 节我的立场，写下你能想到的最强反驳，再尝试替我回应——如果回应不了，就修改立场。这正是本文每一节做的事。

附 范本使用说明（给后续文件作者，含我自己）

把任何一个“专题陈述”升级为“深度探究”，复用这套骨架：

1. 选一个真问题，拆成可处理的子命题（第 0 节）。
2. 挑 1–3 个核心论证，每个走五段式：重构 → 最强反驳 → 回应 → 我的立场 → 悬而未决（第 1、2 节）。
3. 引入至少一个东方视角去“重构问题”，而不是并列陈述（第 3 节）——综合应用的灵魂是让不同传统互相改写问题。
4. 落地一个可交付工具：审计表 / 决策清单 / 可执行研究或实践设计（第 4 节）。
5. 画一张论辩张力地图（谁反驳谁，而非谁属于哪类，第 5 节）。
6. 给出一个会押注的总立场，并标出它的代价（第 6 节）。
7. 诚实列出悬而未决，并留一道让读者继续思考的练习（第 7 节）。

衡量标准只有一条：读完后，读者不只是“多知道了几个观点”，而是“被卷入了一场仍在进行的思考”。

体例：问题驱动横切探究（深度思考 × 综合应用 × 落地）