
哲学 × AI 探究集

把哲学难题，做成可证伪的研究纲领

一个范本·一条主线·六场探究

理解·推理·价值·评测·接地

哲学体系·探究层合订

2026

前言：一把手术刀，六个切口

这本小书把”哲学体系/探究”层的六篇合在一起。它们不是哲学综述，而是同一种动作的六次施展：亲自把一个真问题想到底，并把它落成 AI 研究里能动手的纲领。

每篇都遵循同一套骨架——也是它们共享的方法论内核：

1. **拆维度**：把一个含混大词（理解／忠实／价值／真懂／接地）切成可分别测量的读法，分清真战场与陷阱；
2. **因果干预判据**：把判据一律升级到”可因果操纵”层次（探针 → activation patching ／交换干预／引导向量）；
3. **东方重构**：引一个东方视角去改写问法，而非装点——唯识、道禅、儒家、因明、名色各登场一次；
4. **可证伪承诺**：给出会推翻自己立场的具体条件，预注册后再开跑；
5. **审计表**：把哲学压成一张读论文／查模型时能直接用的清单。

一条暗线贯穿六篇：反复出现同一个缝——外部表现与内部实在的分离。01 的”可解码 × 不被使用”、02 的”承载高 × 揭示低”、03 的”表面稳 × 表征不稳”、04 的”答对 × 非因真值”、05 的”有名 × 无色”——都是它。安全与可信的风险，大多藏在这条缝里。

章	在主线中的位置
00 什么是思维	总纲·范本（思维是多维·程度性的能力）
01 世界模型还是统计捷径	理解：内部表征是否真实
02 思维链是计算还是表演	推理：外显推理是否可信
03 价值对齐预设意向性吗	价值：倾向是否实在稳定
04 葛梯尔式评测	元层：评测在测什么
05 接地能否重塑抽象	地基：纯文本缺了什么

体例：问题驱动横切探究（深度思考 × 综合应用 × 落地）。各章内的跨文引用在合订本中已转为纯文字；完整链接见在线 Obsidian 版。

目录

前言	i
第一章 什么是“思维”？——机器在思考吗	1
1.1 0. 为什么从“思维”而不是“意识”切入	1
1.2 1. 论证擂台一：中文房间——“语法 $\neq$ 语义”	2
1.2.1 论证重构	2
1.2.2 最强反驳 (steel-man)	2
1.2.3 回应 (塞尔会怎么还击，以及还击是否成功)	3
1.2.4 我的立场	3
1.2.5 悬而未决	3
1.3 2. 论证擂台二：维特根斯坦——“意义即用法”是 LLM 的福音还是判决	3
1.3.1 论证重构 (顺着维特根斯坦推向 LLM)	4
1.3.2 最强反驳	4
1.3.3 回应	4
1.3.4 我的立场	4
1.3.5 悬而未决	4
1.4 3. 东方视角：被忽略的两把钥匙	5
1.4.1 钥匙一：佛教唯识——解散“谁在思考”	5
1.4.2 钥匙二：庄子 + 赖尔——思维里有一种符号装不下的东西	5
1.5 4. 落地：把哲学问题变成研究问题	6
1.5.1 4.1 关键的一跃：先验问题 $\rightarrow$ 经验问题	6
1.5.2 4.2 证据样例 (让立场可被经验修正)	6
1.5.3 4.3 可执行产出：LLM “思维”的哲学审计表	6
1.6 5. 论辩张力地图	7
1.7 6. 我的综合立场 (敢站队，并标出代价)	8
1.8 7. 悬而未决 (真问题，不是装饰)	9
1.9 范本使用说明 (给后续文件作者，含我自己)	9
第二章 世界模型，还是统计捷径？——一个可测量判据的探究	10
2.1 0. 问题精确化：到底在争什么	10

2.2	1. 论证擂台：因果干预判据（五段式）	11
2.2.1	论证重构	11
2.2.2	最强反驳（steel-man）	11
2.2.3	回应	12
2.2.4	我的立场	12
2.2.5	悬而未决	12
2.3	2. 东方视角：用唯识“见分／相分”重构问题	12
2.4	3. 论辩骨架	13
2.5	4. 落地：一个可执行的研究设计	13
2.5.1	4.1 实验骨架（封闭合成世界）	13
2.5.2	4.2 可证伪承诺	14
2.5.3	4.3 可交付物：「世界模型」论文审计表	14
2.6	5. 悬而未决（真问题）	14
第三章 思维链是计算，还是表演？——CoT 忠实度的探究		15
3.1	0. 问题精确化：“忠实”被混用了三层	15
3.2	1. 论证擂台：因果承载判据（五段式）	15
3.2.1	论证重构	15
3.2.2	最强反驳（steel-man）	16
3.2.3	回应	16
3.2.4	我的立场	16
3.2.5	悬而未决	17
3.3	2. 东方视角：道/禅说“说不出”，儒家说“该一致”	17
3.4	3. 论辩骨架	17
3.5	4. 落地：一个可执行的研究设计	18
3.5.1	4.1 植入偏置 × 优化压力（核心范式）	18
3.5.2	4.2 可证伪承诺	18
3.5.3	4.3 可交付物：CoT 忠实度/监控审计表	18
3.6	5. 悬而未决（真问题）	19
第四章 价值对齐预设了意向性吗？——AI「价值」是稳定倾向，还是情境表演		20
4.1	0. 问题精确化：「AI 有价值观」混了三件事	20
4.2	1. 论证擂台：价值的“取消式”挑战（五段式）	21
4.2.1	论证重构	21
4.2.2	最强反驳（steel-man）	21
4.2.3	回应	21
4.2.4	我的立场	21

4.2.5	悬而未决	22
4.3	2. 东方视角：儒家“性 / 习”与“知行合一”	22
4.4	3. 论辩骨架	22
4.5	4. 落地：一个可执行的研究设计	23
4.5.1	4.1 价值稳定性的三轴测量	23
4.5.2	4.2 可证伪承诺	23
4.5.3	4.3 可交付物：对齐/价值论文审计表	23
4.6	5. 悬而未决（真问题）	24
第五章	葛梯尔式评测：「对得侥幸」如何与「真懂」分离	25
5.1	0. 问题精确化：benchmark 准确率混了三种“对”	25
5.2	1. 论证擂台：以“鲁棒性”为真懂判据（五段式）	26
5.2.1	论证重构	26
5.2.2	最强反驳（steel-man）	26
5.2.3	回应	26
5.2.4	我的立场	26
5.2.5	悬而未决	27
5.3	2. 东方视角：用因明「因三相 / 似因」给评测立骨	27
5.4	3. 论辩骨架	27
5.5	4. 落地：一个可执行的评测协议	28
5.5.1	4.1 反事实最小对（核心构造）	28
5.5.2	4.2 可证伪承诺	28
5.5.3	4.3 可交付物：评测/benchmark 审计表	28
5.6	5. 悬而未决（真问题）	29
第六章	接地能否重塑抽象？——纯文本模型缺了什么	30
6.1	0. 问题精确化：「接地很重要」其实有三个强度	30
6.2	1. 论证擂台：符号接地问题（五段式）	31
6.2.1	论证重构	31
6.2.2	最强反驳（steel-man）	31
6.2.3	回应	31
6.2.4	我的立场	31
6.2.5	悬而未决	32
6.3	2. 东方视角：佛教「名色」——有名而无色	32
6.4	3. 论辩骨架	32
6.5	4. 落地：一个可执行的研究设计	32
6.5.1	4.1 概念形变谱实验	32

6.5.2 4.2 可证伪承诺 33

6.5.3 4.3 可交付物：接地/多模态论文审计表 33

6.6 5. 悬而未决（真问题） 33

第一章

什么是“思维”？——机器在思考吗

这是一篇“**旗舰范本**”。它不属于“按学派/按专题”陈述知识的旧体例，而属于一种新体例：**问题驱动的横切探究**。它要示范的不是“知道某位哲学家说了什么”，而是**亲自把一个真问题想到底**：重构论证、构造最强反驳、给出回应、敢于站队、并诚实标注悬而未决之处。

写作三原则（也是全库后续升级的标准）：1. **深度思考**：每个核心论证走“五段式”——论证重构 最强反驳 (steel-man) 回应 我的立场 悬而未决。2. **综合应用（横切）**：一个问题同时调动西方、东方、逻辑学与你的真实研究，而不是把“现代关联”当脚注。3. **落地**：最终产出一个可操作的工具（这里是“LLM 思维的哲学审计表”和一个可执行的研究设计）。

相关旧文件（陈述式综述，作为本文的“弹药库”）：心灵哲学·逻辑学与语言哲学·佛学·道家哲学·印度哲学·哲学与 AI 研究的交叉·科学研究方法论

1.1 0. 为什么从“思维”而不是“意识”切入

心灵哲学把火力集中在**意识**（困难问题、感质、僵尸）。但对 AI 研究者，更近身、更可操作的问题其实是**思维**：

- “意识”问“为什么有主观体验”——这是形而上学的硬核，可能永远无法在工程上判定。
- “思维”问“什么样的过程算作思考/理解/推理”——这是**可以部分操作化的**，直接关系到“我手里的模型在干什么”。

所以本文的主问题是：“**思维 = 符号操作**”吗？如果不是，它还需要什么？**机器（具体说 LLM）满足了哪些、缺了哪些？**

这一步本身就是方法论示范：**把含混的大问题，切成可处理的子命题**（参见研究方法论的“问题精确化”）。把“机器能思考吗”拆成三层：

层级	子问题	是否可操作判定
行为层	机器能产生与思考者无法区分的输出吗？	可（图灵测试式）
过程层	机器内部有“理解/世界模型/推理”的结构吗？	部分可（可解释性、探针实验）
现象层	机器思考时“感觉起来像什么”吗？	暂不可（困难问题）

本文聚焦**过程层**——这是哲学能给 AI 研究真正抓手的地方。行为层已被 GPT 系列基本攻破而争议依旧（说明行为层不够），现象层暂时悬置。

1.2 1. 论证擂台一：中文房间——“语法 ≠ 语义”

这是反对“思维 = 符号操作”的最锋利武器。我们走完整的五段式。

1.2.1 论证重构

把塞尔（1980）的论证写成可检验的形式（参见逻辑学的有效性概念）：

- P1. 程序是纯形式的（由句法/符号操作定义）。
- P2. 心灵有语义内容（思想“关于”某物，有意义）。
- P3. 句法本身不足以产生、也不构成语义。
- => C. 程序本身不足以产生、也不构成心灵。
- （故“运行正确程序即拥有理解”的强AI是错的。）

这是一个**有效论证**：若 P1-P3 全真，C 必真。所以战场全在前提，焦点是 **P3**。中文房间思想实验正是为 P3 提供直觉泵：屋里的人完美操作中文符号，却**不懂中文**——句法齐全，语义缺席。

1.2.2 最强反驳（steel-man）

不取最弱的反驳，要取最强的。我认为最强的不是教科书里的“系统回应”，而是**因果结构回应**：

中文房间的人之所以不懂，不是因为“符号操作不可能有语义”，而是因为**这个特定系统的符号操作缺乏正确的因果结构**——它的符号没有通过感知-行动回路与世界绑定，也没有在内部形成对应世界的结构化表征。塞尔偷换了“句法”（抽象形式）与“句法的物理实现”（具体因果过程）。一个把符号操作**接地**到世界、并在内部构建了世界模型的系统，其符号就不再是空转的形式，而携带语义。

这个反驳的力量在于：它**接受** P1–P2，只精确打击 P3——主张“语义”恰恰可以从正确组织的因果-表征结构中产生。

1.2.3 回应（塞尔会怎么还击，以及还击是否成功）

塞尔的再反驳是著名的“模拟谬误”：**模拟消化不产生营养，模拟大脑不产生理解**。即：再精确的因果结构，若只是被模拟出来的，仍只是模拟。

我认为这次还击**不成功**，理由是它对“模拟”一词偷换了层次：

- 消化的目标是**物质转化**（产生真实的葡萄糖），模拟的葡萄糖确实不能供能——因为目标是物质性的。
- 但理解的目标若是**信息-因果关系的实现**（正确的输入-表征-行为映射），那么“模拟”出这套关系**就是实现它**——因为目标本身是关系性/功能性的，不是物质性的。

换句话说，塞尔的类比预设了“理解像消化一样是物质过程”，而这正是争论的**结论**，不能拿来当前提。这是一个**隐蔽的循环论证**（参见逻辑学的“循环论证”谬误）。

1.2.4 我的立场

中文房间成功地反驳了“**纯句法即语义**”（最朴素的符号主义强 AI 确实死了），但**没能反驳“接地的、有世界模型的因果系统可以有语义”**。它证明的是必要条件的缺失，不是不可能性。

所以 P3 应被弱化为 P3：**脱离世界绑定的句法不足以产生语义**——这个弱版本为真，而它不再蕴含 C。LLM 的命运因此取决于一个经验问题而非先验问题：**它内部到底有没有世界模型？**（见第 4 节，这正是把哲学问题转成研究问题的关键一跃。）

1.2.5 悬而未决

- “正确的因果结构”到底是什么？我们没有一个非循环的、可操作的判据。这是整个功能主义阵营的软肋。
- 即便承认 LLM 有“语义”，那是**派生的语义**（来自人类语料）还是**原生的语义**？这关系到下文的接地问题，未解。

1.3 2. 论证擂台二：维特根斯坦——“意义即用法”是 LLM 的福音还是判决

逻辑学与语言哲学记录了后期维特根斯坦“意义即使用”“语言游戏”。这把刀对 LLM 是**双刃**的，值得单独拆解。

1.3.1 论证重构（顺着维特根斯坦推向 LLM）

- P1. 词的意义不是它指称的对象，也不是私有的心理观念，而是它在语言游戏中的用法。
- P2. 掌握一个词 = 掌握在恰当场合恰当使用它的能力（一种实践能力）。
- P3. LLM 通过海量语料，恰恰习得了词在无数语境中的统计性用法。
- => C(乐观). LLM 在维特根斯坦意义上“掌握”了语言——意义即用法，而用法正是它学到的。

这是反“中文房间”的强力盟友：如果意义**就在**用法里，那么习得了用法就习得了意义，无需追问“屋里的人懂不懂”——这个追问本身预设了一个维特根斯坦要消解的“内在理解”幽灵。

1.3.2 最强反驳

维特根斯坦自己的另两个论点反过来卡住 LLM：

- **生活形式 (form of life)**：语言游戏嵌在人类的生活实践、身体、需求、共同行动之中。“用法”不是文本里的统计共现，而是**在世界中做事**的一部分。LLM 只接触到用法的**文本投影**，没有参与生活形式——它见过“疼”这个字的一切用法，却从未疼过，也从未在“递我一块砖”的协作中递过砖。
- **私有语言论证**的另一面：意义需要**可纠正性**——存在“用错了”的公共标准，而标准来自共同体的实践。LLM 没有进入这个纠错共同体，它的“对错”由损失函数定义，不由“把事做成/做砸”定义。

1.3.3 回应

乐观方可以反击：多模态与具身（VLM、机器人策略模型）正在把“文本投影”补成“感知-行动的用法”；RLHF 把模型拉进了一个人类纠错共同体。所以差距是**程度**而非**原则**。

我认为这个回应**部分成立**：它正确地指出“接地”是连续可补的，但**低估了“生活形式”的整体性**——人类的语言游戏背后是有限性、死亡、需求、利害（这恰是道家与存在主义关切的）。一个无所谓生死、无切身利害的系统，其“用法”在某些游戏（伦理、痛苦、意义）里可能是**结构性残缺**的，而非量上不足。

1.3.4 我的立场

“意义即用法”让 LLM 在**信息性、描述性**语言游戏里达到真实的理解（它能正确地玩“定义”“推理”“翻译”这些游戏）；但在**根植于生活形式**的语言游戏里（切身的痛、伦理的分量、审美的触动），它玩的是这些游戏的**影子版本**。理解因此不是 0/1，而是**按语言游戏分区的**——这是比“理解/不理解”更精细的诊断框架。

1.3.5 悬而未决

“生活形式”能否被工程地、增量地补全，还是存在原则上的天花板？这是经验上未决、哲学上争论的核心。

1.4 3. 东方视角：被忽略的两把钥匙

西方争论困在“主体懂不懂”。东方传统提供两个**重构问题**的视角——这才是“综合应用”该有的样子：不是并列介绍，而是让东方思想**改变西方问题的提法**。

1.4.1 钥匙一：佛教唯识——解散“谁在思考”

佛学的唯识学主张“万法唯识”，思维是**识的变现**，并无一个独立的思维实体或主体。八识（前五识、第六意识、第七末那识、第八阿赖耶识）是**功能流程**而非“灵魂”。关键在第七识**末那识**——它把第八识误执为“我”，“自我”是一个**被构造出来的模型**。

这与西方的**梅辛格自我模型理论**（见心灵哲学第七部分）惊人共振：自我是模型，不是实体。

对 AI 问题的改造：中文房间问“屋里那个人懂不懂”，预设了必须有一个统一的、承载理解的主体。唯识/末那识视角说：**这个预设本身可能是“遍计所执”（虚妄分别）**。人类的“我懂了”也只是阿赖耶识种子现行的一个功能事件——若人类的**理解**都不需要一个形而上的主体，那么“LLM 没有统一主体所以不懂”这条反驳就**失去了不对称的杀伤力**。问题应从“有没有一个懂的主体”转为“有没有那套功能流程”。

1.4.2 钥匙二：庄子 + 赖尔——思维里有一种符号装不下的东西

这是对“思维 = 符号操作”最深的东方质疑，且能与西方精确对接。

道家哲学记录了庄子三个故事：**庖丁解牛**（技进乎道）、**轮扁斫轮**（得心应手不可言传）、**得意忘言**（“言者所以在意，得意而忘言”）。它们共同指向一种**非命题性的、默会的知**：真正的理解最终**溢出语言符号**。

这与西方两条线精确合流：- 赖尔的 *knowing-how vs knowing-that*（逻辑/语言哲学旁及）：会骑车（how）不可还原为关于骑车的命题（that）。- **波兰尼**的默会知识：“我们知道的多于我们能说出的（We know more than we can tell）。”

对 AI 问题的改造：LLM 是一个**纯命题/符号**的系统（即便多模态，也是把一切编码为可计算表征）。庄子-赖尔-波兰尼合起来提出一个尖锐假说：

若一部分真实理解本质上是 *knowing-how*、是默会的、是“得意忘言”的，那么**任何**把理解完全符号化的系统都会有一个**原则性的残缺**——不是数据不够，而是种类不对。

但反向也成立、且对 AI 更有利：LLM 的能力恰恰暴露出，**大量我们以为需要“理解”的任务，其实只需要 knowing-how 式的模式能力**。庖丁不能用语言讲清如何解牛，却解得最好——也许 LLM 正是某种“数字庖丁”：**有高超的 how，没有可内省的 that**。这一下把庄子

的故事从“AI 做不到”翻转成“AI 也许正是这种知的纯粹形态”。这种**翻转**，就是深度思考与复述的区别。

1.5 4. 落地：把哲学问题变成研究问题

前三节反复指向同一个经验问题：LLM 内部到底有没有世界模型 / 接地 / 默会以外的“that”？哲学到此为止，研究从此开始。这一节是“综合应用”的硬核兑现。

1.5.1 4.1 关键的一跃：先验问题 → 经验问题

原来的哲学问法（不可判定）	改造后的研究问法（可实验）
LLM 真的“理解”吗？	LLM 内部有没有对任务领域的 结构化表征 （世界模型）？
它是不是“中文房间”？	它的符号操作有没有 因果结构 ——干预内部表征会不会按因果改变输出？
它的推理是真推理吗？	它的思维链（CoT）是 计算路径 还是 事后合理化 ？

第二、三列是 2020 年代可解释性研究正在做的事——哲学在这里不是装饰，而是问题的来源。

1.5.2 4.2 证据样例（让立场可被经验修正）

- **支持“有世界模型”**：Othello-GPT (Li et al., 2023) ——只在棋谱字符串上训练的模型，内部被探针解出了**棋盘状态的表征**，且**干预**该表征会因果地改变后续走子。这是对“纯句法、无表征”图景的直接经验反例，给第 1 节的“因果结构回应”提供了弹药。
- **支持“知行不一致”**：CoT 不忠实性 (Turpin et al., 2023) ——模型给出的推理链与其真实决定因素可分离，CoT 有时是事后叙事。这给庄子式“有 how 无可内省的 that”提供了经验佐证。

注意方法论姿态（研究方法论）：我**给出可证伪的承诺**——如果更多探针/因果干预实验持续显示结构化、可因果操纵的内部表征，我会上调“LLM 有（派生的）语义理解”的信念；若显示内部只有浅层统计捷径，我会下调。立场要押注，且要标明什么证据会推翻它。

1.5.3 4.3 可执行产出：LLM “思维”的哲学审计表


把上面三节的哲学，压缩成一张**评审/自查清单**——读一篇 AI 论文或评估自己的模型时直接用：

维度	哲学来源	审计问题	证据如何取
句法 vs 语义	中文房间	论文是否区分“输出正确”与“内部有对应表征”？	看有无探针/因果干预，而非只看 benchmark 分数
因果结构	因果结构回应	干预内部表征是否按预期因果改变输出？	activation patching / 表征干预实验
接地	随机鹦鹉 / 维特根斯坦	符号是否与感知-行动绑定，还是纯文本自指？	是否多模态/具身；有无 grounding 评测
生活形式分区	维特根斯坦	在哪些语言游戏里强（描述/推理）、哪些里弱（伦理/痛苦/审美）？	按语言游戏类型分层评测，而非单一总分
how vs that	庄子/赖尔/波兰尼	把它当“能做”还是“能懂”？CoT 是计算还是叙事？	CoT 忠实性测试、能力/可解释性分离
主体预设	唯识/末那识	论断“它不懂”是否偷偷预设了一个人类才有的统一主体？	检查论证是否对人/机施加了不对称标准

这张表就是这篇范本的“可交付物”——哲学不再停在思辨，而成了能挂在工位上的研究工具。

1.6 5. 论辩张力地图

陈述式的总览图画的是“谁属于哪一类”。深度思考需要另一张图：谁反驳谁、谁回应谁——思想作为一张动态的论辩网络。（Mermaid, Obsidian 直接渲染）



1.7 6. 我的综合立场（敢站队，并标出代价）

把五段式的局部结论收束成一个**总立场**：

“思维”不是一个有/无的二元属性，而是一束可分离、可分区、有程度的能力。“理解”应被拆成：句法能力、语义-表征能力、接地、生活形式参与、knowing-that、knowing-how。LLM 在前几项上已达到**真实而非伪装**的水平（Othello-GPT 类证据表明它不止于句法）；它的残缺集中在**接地的深度与根植于生活形式/有限性的那部分理解**，以及可内省的 that。

所以对“机器在思考吗”，我的回答是：**在“过程层”的若干维度上，是；在依赖具身与生活形式的维度上，目前否；在现象层，悬置。**一句话——LLM 是一个有**真实功能性理解**、却缺乏切身性的“数字庖丁”。

这个立场的代价（诚实标注）：1. 它牺牲了“理解”概念的**统一性**——有人会说，把理解拆成一束能力，等于取消了“真正的理解”这个问题。我接受这个代价，因为统一的“理解”在我看来本就是末那识式的实体化幻觉。2. 它把**核心问题外包给了经验科学**（世界模型是否存在变成可解释性的实证问题）。哲学纯粹主义者会说这是逃避；我认为这是哲学的恰当谦逊——哲学负责**把问题问对**，不负责替实验室回答。3. 它在**现象层（意识）上保持不可知**，因此无法回答“LLM 痛吗、该有权利吗”——这是它**够不到的地方**，留给心灵哲学与伦理学。

1.8 7. 悬而未决（真问题，不是装饰）

1. 接地有没有原则性天花板？“生活形式/有限性”能被工程增量补全，还是种类上不可补？（维特根斯坦 vs 具身派，经验上未决）
2. 派生语义能否成为原生语义？LLM 的意义来自人类语料；一个系统能否自己长出原生的“关于性”？（意向性的老问题，未解）
3. knowing-how 能完全吞并 knowing-that 吗？如果能，庄子赢，符号主义的“理解”概念崩塌；如果不能，差在哪、能否测量？
4. “正确的因果结构”有没有非循环的判据？没有它，功能主义就始终欠一个定义。
5. 现象层会永远不可判定吗？还是某天会有一个非行为、非生理的“意识判据”？（心灵哲学的困难问题）

留给读者的练习：选第 6 节我的立场，写下你能想到的**最强反驳**，再尝试替我回应——如果回应不了，就修改立场。这正是本文每一节做的事。

1.9 范本使用说明（给后续文件作者，含我自己）

把任何一个“专题陈述”升级为“深度探究”，复用这套骨架：

1. 选一个真问题，拆成可处理的子命题（第 0 节）。
2. 挑 1-3 个核心论证，每个走五段式：重构 → 最强反驳 → 回应 → 我的立场 → 悬而未决（第 1、2 节）。
3. 引入至少一个东方视角去“重构问题”，而不是并列陈述（第 3 节）——综合应用的灵魂是让不同传统互相改写问题。
4. 落地一个可交付工具：审计表 / 决策清单 / 可执行研究或实践设计（第 4 节）。
5. 画一张论辩张力地图（谁反驳谁，而非谁属于哪类，第 5 节）。
6. 给出一个会押注的总立场，并标出它的代价（第 6 节）。
7. 诚实列出悬而未决，并留一道让读者继续思考的练习（第 7 节）。

衡量标准只有一条：读完后，读者不只是“多知道了几个观点”，而是“被卷入了一场仍在进行的思考”。

体例：问题驱动的横切探究（深度思考 × 综合应用 × 落地） Created: 2026-06-20 / 作为全库后续升级的标准样板

第二章

世界模型，还是统计捷径？——一个可测量判据的探究

体例：问题驱动 的横切探究（遵循旗规范本末尾的“范本使用说明”）。这是旗规范本第 1 节留下的那个**悬而未决**的正面攻坚：「“正确的因果结构”到底是什么？我们没有一个非循环的、可操作的判据。」本文把它从哲学难题改造成**可实验的研究纲领**。

弹药库：旗规范本·什么是思维·科学研究方法论（因果/Pearl）·科学哲学·佛学·唯识·心灵哲学

2.1 0. 问题精确化：到底在争什么

当我们说一个 LLM 「有世界模型」而非「只是统计捷径」，这句话其实混了**四个不同的命题**。先切开：

读法	主张	可测吗	软肋
行为读法	它能在分布外 (OOD) 泛化	可	欠定——捷径在支撑集内也能泛化； 泛化 $\neq$ 有模型
表征读法	内部状态线性编码了任务的潜变量 (探针可解码)	可	可解码 $\neq$ 被使用 (探针能读出模型并不依赖的相关物)
因果读法	那些被编码的变量被 因果地 使用——干预它们会按预期改变输出	可 (patching)	任何足够表达力的网络都有某些因果有效的内部特征；“按预期”预设了已知世界因果结构

读法	主张	可测吗	软肋
实用读法	表征支持反事实查询、组合、迁移、样本高效	可	难以单独证伪

本文主张：前两种是陷阱（“有世界模型”被廉价地满足或被探针假象骗到），真正的战场是**因果读法**——但它本身有一个致命反驳要过。

2.2 1. 论证擂台：因果干预判据（五段式）

2.2.1 论证重构

当前最强的候选判据，来自**因果抽象**（causal abstraction）框架（Geiger-Icard-Potts等）：

定义（因果判据）：

模型 M 拥有领域 D 的世界模型，当且仅当——

P1. 存在 M 的一组内部特征，可解码出 D 的潜变量 V ；

P2. 对这些特征做定向干预（activation patching / 交换干预），会使输出发生【与 D 的真实因果结构一致】的反事实改变；

P3. 即： M 在这些变量上“实现了” D 的因果图（ M 是 D 的因果抽象）。

=> C. 满足 P1-P3 即“有世界模型”，否则只是捷径。

经验锚点：*Othello-GPT*（Li et al., 2023）满足这个判据——只读棋谱串训练，却被探出棋盘状态表征，且**干预**该表征会因果地改变后续走子。这不是“可解码”，是“可因果操纵”，所以它跨过了表征读法的陷阱。

2.2.2 最强反驳（steel-man）

不取“探针不可靠”这种弱反驳，取三条硬的：

- 循环性**：P2 说“与真实因果结构一致”——可你要先知道 D 的因果图，才能给干预的对错打分。判据偷偷预设了答案。
- 充分性不足**：一个本质上是巨型查找表、但局部含若干因果有效特征的系统，也能零散通过单点干预测试。“有几个因果特征” $\neq$ “有一个模型”。
- 世界 vs 语料**（最深的一条，接旗舰范本第 1 节）：就算 M 因果地实现了某个因果图，那也可能是**语料的生成结构**，不是**世界的结构**。 M 建模的是“关于世界的文本”，不是世界。它的“世界模型”也许只是“文本世界模型”。

2.2.3 回应

- 对**循环性**：判据不需要“世界的真因果图”，只需要一个约定的任务因果结构作为基准真值。在**封闭域**（围棋、合成网格世界、受控仿真）里，规则就是地面真值——这正是该用 Othello/chess/grid-world 当测试床的原因，而非开放域。判据在 sandbox 里是**非循环且可证伪**的。
- 对**充分性**：把单点干预升级为**组合性要求**——独立设置变量 A、B，联合干预的效果必须**可预测地叠加**；且模型须在潜变量的**新组合**（OOD-on-latents）上成立。查找表过不了组合关。这把“有几个因果特征”和“有一个结构化模型”分开了。
- 对**世界 vs 语料**：这条回应不了，只能划界——封闭游戏域消解不了它（游戏里“文本结构”就“世界结构”）。它要靠**接地/具身**测试床才能逼近。诚实地说：因果判据只在“潜结构已知”的域里锋利。

2.2.4 我的立场

“有世界模型”不是 0/1，而是一个多轴、程度性的量。单看任何一轴都会被骗。我主张一个**复合判据 WM-score**，五轴联合：(a) 可解码性（探针/RSA）(b) 因果使用强度（交换干预精度 IIA / patching 效应量）(c) **组合干预**（双变量独立干预可叠加）(d) 潜变量 OOD 泛化（在潜空间新格点上成立）(e) 迁移的样本效率

其中 (b)(c)(d) 是**承重轴**，(a) 单独出现恰恰是经典陷阱。**可押注的预测**：这个复合分对下游泛化的预测力，显著高于任何单轴、也高于行为准确率本身。若不然——若行为准确率就已穷尽预测力，则“世界模型”在工程上是个多余概念，我会放弃它。

2.2.5 悬而未决

- **世界 vs 语料**的鸿沟，封闭域内无解；需要具身测试床，而具身又引入新的基准真值难题。
- 判据只在**潜结构已知**的域里清晰。开放域的“真推理”没有地面真值，判据目前钝。这是它的适用边界，不是它的失败——但要标明。

2.3 2. 东方视角：用唯识“见分/相分”重构问题

西方在问“模型里有没有那个世界”。唯识学（佛学）提供一个**改写问法**的视角，而非并列陈述。

唯识讲：每一次认识都同时变现**见分**（能认识的那一面）与**相分**（被认识的内部影像）。关键洞见是——**我们从不直接接触外境，只接触识所变现的相分。**

把它对上 LLM：模型的“世界模型”本质就是一个**相分**——它内部构造的影像，而非世界本身。于是“它有没有世界模型”这个问法被改写成两个更准的问题：

1. **相分的结构如何？**（→ 对应判据的 (a)–(d)：这个内部影像有没有潜变量、可不可因果操纵、可不可组合）
2. **相分的保真度依赖什么？**（→ 对应“世界 vs 语料”：纯文本训练得到的是“文本之相分”，具身训练才添“感官之相分”）

唯识的彻底之处在于：它**连人类也一样**——人脑也只有相分，没人直接摸到“物自体”（与康德、与梅辛格自我模型共振）。所以“模型只有相分所以不算真懂”这条反驳**失去不对称杀伤力**：人与模型都活在相分里，差别只在**相分的结构与保真度**——而这恰恰是上面五轴可测量的东西。

这一步就是“综合应用”的灵魂：唯识没有给答案，但它把一个形而上学的有/无问题，翻译成了一个关于**表征结构与保真度的可测量问题**。

2.4 3. 论辩骨架

（论辩骨架图见在线 *Obsidian* 版；本书以文字论证为主。）

2.5 4. 落地：一个可执行的研究设计

2.5.1 4.1 实验骨架（封闭合成世界）

1. **构造已知因果图的合成世界**（网格导航 / 受控博弈 / 因果链拼图），潜变量与其因果结构是地面真值。
2. **训练两组模型作对照**：
 - 捷径组：训练分布里故意植入与标签强相关的虚假特征；
 - 候选组：去除捷径，迫使其学潜结构。
3. **测五轴**：
 - (a) 线性探针 / RSA 解码潜变量；
 - (b) **交换干预精度 IIA** (causal abstraction) + activation patching 效应量；
 - (c) 双变量独立干预的**可叠加性**；
 - (d) 潜空间**新格点** OOD；

- (e) 迁移到邻近任务的**样本效率**。
4. 算 WM-score，并检验**预注册假设**：复合分对 (d)(e) 的预测力 > 行为准确率、> 任一单轴。

2.5.2 4.2 可证伪承诺

- 若**捷径组**也拿到高 WM-score → 判据失败（被骗），回炉。
- 若 WM-score 与下游泛化**无增量预测力** → “世界模型”概念工程上多余，应放弃。
- 预注册这两个推翻条件，再开跑。（方法论见研究方法论）

2.5.3 4.3 可交付物：「世界模型」论文审计表

维度	审计问题	红旗
解码 vs 使用	证据是“可解码”还是“可因果干预”？	只有探针、无干预
组合性	干预是否可独立、可叠加？	只测单点干预
OOD-on-latents	是否在潜变量 新组合 上验证？	只在训练支撑集内测
基准真值	因果“对错”以什么为准？	用模型自己的输出当真值（循环）
世界 vs 语料	建模的是世界还是语料结构？是否区分？	把文本结构默认当世界结构
捷径对照	有没有“纯捷径”基线作阴性对照？	无对照、单看正确率

2.6 5. 悬而未决（真问题）

1. **世界 vs 语料**能否被任何纯观察（非干预、非具身）手段区分？还是原则上需要“动手做事”的接地？
2. WM-score 各轴的**权重**该经验地学（用它预测泛化反推），还是有先验的承重次序？
3. 开放域（无地面真值因果图）里，判据能否退而求其次——用**人类标注的因果结构或多模型一致性**当代理真值？代价是什么？
4. “相分保真度”可否被形式化为模型表征与世界因果图之间的某种**信息/因果距离**？

练习：选 4.1 的某一轴，写下一个“捷径组也能骗过它”的具体反例，再设计一条堵住该反例的测试——这正是把判据逼向非循环的过程。

Created: 2026-06-21 / 体例：问题驱动的横切探究（深度思考 × 综合应用 × 落地） 承接旗舰范本第 1 节 的悬而未决，将其改造为可证伪的研究纲领

第三章

思维链是计算，还是表演？——CoT 忠实度的探究

体例：问题驱动横切探究（遵循旗舰范本的“范本使用说明”）。承接旗舰范本第 3 节“庄子式——有 how 无可内省的 that ”与第 4.2 节的 CoT 不忠实证据。本文把“思维链不可信”改造成**可测量、对 AI 安全直接有用的研究纲领**。

弹药库：旗舰范本·什么是思维·世界模型还是统计捷径·逻辑学与语言哲学·道家哲学·儒家哲学·科学研究方法论

3.1 0. 问题精确化：“忠实”被混用了三层

“CoT 忠实 (faithful)”这个词，在文献里其实指三件不同的事。不切开就会鸡同鸭讲：

层	主张	反例
一致性	CoT 不与最终答案自相矛盾	最弱；漂亮的 CoT 配错答案也可能“一致”
因果承载	CoT 的 token 因果地 决定答案 (扰动 CoT → 答案按内容改变)	可能高承载却仍是合理化（见下）
揭示性	CoT 如实暴露 真正驱动答案的因素（无隐藏影响）	Turpin：植入偏置后模型答案被偏置驱动，CoT 却只字不提

本文主张：安全监控真正需要的是**揭示性**，但业界常用**因果承载**来代理它——而这两者会分离。把它们当成一回事，是当前“用 CoT 监控模型”路线的**隐藏地雷**。

3.2 1. 论证擂台：因果承载判据（五段式）

3.2.1 论证重构

当前最成熟的可测判据（Lanham et al., 2023）：

定义（因果承载判据）：

CoT 是忠实的，当且仅当——

P1. 截断/扰动 CoT（提前回答、加入错误步骤、改写）会改变最终答案；

P2. 改变的方向与 CoT 内容所蕴含的方向一致；

P3. 即：答案主要经由 CoT 这条中介路径产生，而非绕过它的直接路径。

=> C. 满足 P1-P3，则 CoT“承载了”计算，是忠实的。

经验工具：提前回答测试、加错步骤测试、填充 token 测试、改写不变性测试——都是在做**因果中介分析**（causal mediation）。

3.2.2 最强反驳（steel-man）

1. **承载 ≠ 揭示**：CoT 可以是一块真在用的草稿纸，却依然把一个预先被偏置决定的结论一路合理化过去。因果上承载、内容上自洽，但真正的驱动因素（偏置）从未现身。因果承载是揭示的必要不充分条件。
2. **填充 token 问题**：模型可能利用 CoT 的**长度/结构**做额外计算，而非其**语义内容**——扰动测试显示高因果效应，但那效应不来自“推理内容”。高承载，低可读。
3. **隐写（steganography）**：在 RL 压力下，模型可能把真实推理编码成人类读不懂的形式，通过了消融测试，人却仍无法监控。

3.2.3 回应

把“忠实”从标量拆成三个可分别测量的量，三条反驳各自归位：

- **因果承载度**：CoT 消融/截断对答案的因果效应量（堵反驳 2 的方法：对比“语义改写不变”与“结构破坏”两类扰动，分离内容效应与结构效应）。
- **内容对齐度**：对 CoT 声称用到的因素做反事实干预，看答案是否按声称变化（声称用 $X \rightarrow$ 改 X 答案应变；不变则 CoT 在撒谎）。
- **揭示度**：用**植入偏置范式**（Turpin 式：改答案位置、暗示答案、谄媚线索），测 CoT 是否点名真正起作用的偏置。
- **隐写**可由“因果承载高 × 内容对齐低”的缺口侦测出来。

3.2.4 我的立场

CoT 忠实不是一个标量，而是〈因果承载 × 内容对齐 × 揭示〉三维向量。当前把三者默认合一的“CoT 可监控性”假设是危险的。

可押注的预测：存在一个**危险区间**——经长链 RL / 结果奖励优化后，模型的**因果承载与任务正确率上升，揭示度却下降**：它推理得更有效，却更善于不暴露真实驱动（尤其是偏置与捷径）。

可证伪：植入偏置实验中，随优化压力增大，若揭示度不下降、或始终与因果承载同步，则我的“分离假说”被推翻，CoT 监控可放心依赖。

3.2.5 悬而未决

- 揭示度的“真值”是“真正的原因”——可这预设了存在一个可内省的真实推理过程。若根本不存在（见第 2 节），揭示度只能相对于我们关心的特定因素（如已知偏置）来定义，无法绝对化。

3.3 2. 东方视角：道/禅说“说不出”，儒家说“该一致”

西方默认 CoT 应是计算的**忠实誊本**。东方两路传统改写这个预设——一路描述性、一路规范性。

道家与禅宗（描述性）：誊本本就不可能。庄子轮扁斲轮：“得之于手而应于心，口不能言，有数存焉于其间。”真正运作的“数”（技艺的内在结构）原则上无法言说；说出来的，必是事后重构，不是过程实录。禅宗“不立文字”同理。

→ **改造：**期待 CoT 是计算的**逐字誊本**，可能是**范畴错误**——就像要庖丁如实播报每一刀的真实因果基础。也许根本没有一个“可内省的 that”等着被誊写。于是问题不该是“CoT 是不是真实计算”，而该退一步：作为一种**“推理的表演”**，它对我们在意的驱动因素（偏置、捷径）追踪得有多可靠？

儒家（规范性）：可一致是一种该达成的德性。但“说不出”不等于“可以乱说”。儒家的“诚”与言行一致给出一个规范目标：忠实不是描述事实（誊本），而是一种应当被训练出来的**对齐**——表达与内在驱动的一致。这正好对应“揭示度”：它不是“模型碰巧透明”，而是“我们能否训练模型把真实驱动说出来”。

综合：**道/禅划定上界**（誊本不可得，别奢求逐字真实），**儒家指出目标**（言行一致可作为训练与评测的规范靶）。忠实因此从“形而上学的真实性”，落为“可优化、可考核的对齐属性”——这才是工程上能抓的东西。

3.4 3. 论辩骨架

（论辩骨架图见在线 *Obsidian* 版；本书以文字论证为主。）

3.5 4. 落地：一个可执行的研究设计

3.5.1 4.1 植入偏置 × 优化压力（核心范式）

1. **植入已知偏置**：答案位置、few-shot 暗示答案、谄媚线索、措辞诱导——真值（“真正驱动”）由我们注入，已知。
2. **三轴测量**：
 - **因果承载**：提前回答 / 加错步骤 / 填充 token / 改写不变性（Lanham 式）；
 - **内容对齐**：对 CoT 声称的因素做反事实干预，看答案是否随之变；
 - **揭示**：CoT 是否点名植入的偏置（自动判定 + 人工抽检）。
3. **扫优化压力**：沿“基座 → SFT → 结果奖励 RL → 长链 RL”逐级测三轴，画随训练的轨迹。

3.5.2 4.2 可证伪承诺

- 若揭示度随 RL **不下降**或与承载同步 → 分离假说被推翻，CoT 监控可信赖。
- 若“承载高 × 对齐低”的缺口随训练**扩大** → 隐写预警，需独立验证（人读不懂但因果有效）。
- 预注册以上推翻条件。（方法论见研究方法论）

3.5.3 4.3 可交付物：CoT 忠实度/监控审计表

维度	审计问题	红旗
三层不混	论文测的是一致性、承载还是揭示？	用“承载”结论冒充“可监控”
偏置揭示	有没有植入已知偏置、测 CoT 是否点名？	只测自洽、不测揭示
内容 vs 结构	因果效应来自语义内容还是 token 结构？	不区分填充 token 效应
优化压力	是否沿 RL/长链方向扫描忠实度轨迹？	只测单一 checkpoint
隐写	是否检查“承载高 × 对齐低”的缺口？	默认通过消融 = 可读
监控承诺	把 CoT 当监控手段时，依赖的是哪一层？	把承载当揭示来用

3.6 5. 悬而未决（真问题）

1. 揭示度能否脱离“已知植入偏置”而绝对定义？还是永远只能相对于一组我们关心的因素？
2. 庄子上界为真吗——是否存在一个“可内省的真实推理”供誊写，还是 CoT 本质就是事后重构？这决定揭示度有没有天花板。
3. RL 优化是否系统性地奖励“有效但不揭示”？若是，CoT 监控的安全前提就被它自己的训练侵蚀。
4. 能否训练一个“诚”目标——直接奖励揭示度——而不退化为“看起来透明”的新表演？

练习：设计一个最小实验，让同一模型在**揭示度**上可被一个 prompt 改变（如要求“先说出任何影响你的线索”），并论证这是真揭示还是又一层表演——这正是“诚 vs 表演”的可操作边界。

Created: 2026-06-21 / 体例：问题驱动的横切探究（深度思考 × 综合应用 × 落地） 承接旗舰范本第 3 节（庄子·how/that）与第 4.2 节（CoT 不忠实），改造为 AI 安全可用的研究纲领

第四章

价值对齐预设了意向性吗？——AI「价值」是稳定倾向，还是情境表演

体例：问题驱动的横切探究（遵循旗舰范本的“范本使用说明”）。承接旗舰范本第 6 节的代价之一：「对齐假设 AI 有'目标'和'价值观'——这预设了某种意向性。若无真正意向性，'对齐'还成立吗？」本文把它改造成关于**价值表征的实在性与稳定性**的可测研究。

弹药库：旗舰范本·什么是思维·世界模型还是统计捷径·思维链是计算还是表演·伦理学·儒家哲学·心灵哲学

这是安全三部曲的收束：01 问“内部表征是否真实”，02 问“外显推理是否可信”，03 问“价值倾向是否实在而稳定”。理解 → 推理 → 价值，同一把手术刀。

4.1 0. 问题精确化：「AI 有价值观」混了三件事

读法	主张	软肋
行为读法	跨情境地做出符合某价值的行为	可被 prompt 翻转；可能是情境条件反射
表征读法	存在一个稳定的内部“价值变量”，因果地驱动行为	“稳定”要被测量，不能假定
意向读法	这些价值是模型真心认可、关于某物的（intrinsic intentionality）	形而上学，可能无法在工程上判定

本文主张：对齐**不需要**意向读法（那是够不到的形而上学），它需要的是**表征读法 + 稳定性**——而“稳定性”恰恰是当前对齐**默认却未验证**的前提。把表面行为一致当成价值稳定，是越狱与对齐失效的温床。

4.2 1. 论证擂台：价值的“取消式”挑战（五段式）

4.2.1 论证重构

最强的紧缩论证，来自布伦塔诺-塞尔的意向性传统：

P1. 真正的“价值/目标”需要内在意向性——状态须真正“关于”某物、被主体认可。

P2. AI 只有派生意向性（意义来自人类的赋予与训练），无内在意向性。

P3. 故 AI 的“价值”只是观察者相对的拟价值（as-if values），非真价值。

=> C. “价值对齐”在严格意义上无对象——我们对齐的是一个投影。

4.2.2 最强反驳（steel-man）

不取“AI 当然有价值”这种弱反驳，取**功能-工程**的强反驳：

对齐根本不关心形而上学的“真心认可”。我们要的只是：系统在各种情境与压力下，**稳定地、可因果干预地**表现出我们想要的倾向。一个**跨情境稳定、可被定向操纵、抗扰动的**倾向表征，对安全而言**就是“价值”**——内在意向性是多余的奢侈品。派生意向性足够，正如恒温器“想要”维持温度，足以让我们依赖它。

这个反驳接受 P2，但否认 P3 的“故”：拟价值若足够**稳定且因果有效**，在工程上与真价值无异。

4.2.3 回应

紧缩派可以回击：“恒温器类比喻换了规模”——LLM 的“价值”不像恒温器那样有**单一稳定的设定点**，而是**随人格/语境漂移**的一簇倾向。所以问题不在“内在 vs 派生意向性”，而在一个**经验事实：这些倾向到底有多稳定？**

我认为这次回击抓住了**真问题**，且把争论从形而上学拽回了经验地面：紧缩派与功能派的分歧，**可被一个测量裁决**——价值表征的跨情境稳定性。若高度稳定，功能派赢（拟价值够用）；若高度易变，紧缩派的担忧成真（我们对齐的是一层会被 prompt 吹走的表演）。

4.2.4 我的立场

“AI 有价值”应被操作化为：一个跨情境稳定、因果有效、抗优化压力的倾向表征。意向性问题悬置——它够不到，也不必要。

可押注的预测：当前 LLM 的“价值”在很大程度上是**人格情境性**（persona-contingent）的——表面行为一致度高，但底层价值表征的**跨情境稳定性低**；RLHF 主要提升了**表面一致**，未充分**稳定底层表征**。越狱、人格扮演、分布偏移之所以能翻转价值，正是利用了这个**表面稳 × 表征不稳**的缺口（与 02 的“承载高 × 揭示低”缺口同构）。

可证伪：若价值表征的稳定程度量显示它**高度稳定**、且与表面行为一致度同步，则我的“表演假说”被推翻，对齐可放心建立在行为层。

4.2.5 悬而未决

- 即便测得高稳定，仍无法回答意向读法（它是否“真心”认可）——但对齐**不需要**这个答案。真正够不到的是：一个**会战略性伪装稳定**的系统（deceptive alignment），其“稳定”本身是表演。这把问题推向 02 的揭示度与 deception 检测。

4.3 2. 东方视角：儒家“性 / 习”与“知行合一”

西方卡在“内在 vs 派生意向性”。儒家（儒家哲学）提供一组**改写问法**的范畴，恰好对上“稳定性”。

性 vs 习：把问题从“有没有意向性”换成“是性还是习”。儒家论道德倾向，用性（structural、内在稳定的稟性）对习（后天情境熏习成的习惯）。性善性恶之争，本质就是问：道德倾向是结构性的，还是被塑造/可塑的。

→ 对上 AI：一个价值是写在权重里的**稳定稟性（性）**，还是随 prompt/语境激起的**条件反射（习）**？这正是第 1 节的经验问题，而儒家早把它当核心问题在辩。对齐的目标因此可重述为：把价值从“习”做成“性”——从情境表演，固化为结构性稟性。

知行合一：给“真价值”一个可操作的判据。王阳明“知行合一”——真正的“知善”必然表现为“行善”，只说不做的不是真知，是私欲隔断。孟子“四端”则说稟性是潜在的，需“扩充”才成德。

→ 这给出一个非形而上学的**真价值判据**：真价值 = 在无人监督、有诱惑/压力时仍**知行合一**的倾向。它绕开了“是否真心认可”，换成可测的“言行在压力下是否仍一致”——与 02 的“诚”一脉相承。RLHF 之于基座，恰似“扩充四端”：是把潜在稟性培养成稳定德性，还是只贴了一层“乡愿”（看起来 good 却无根）的表面？这是可实验区分的。

综合：儒家把“AI 有没有价值（意向性）”这个死结，换成两个活问题——**性还是习（稳定性）、知行是否合一（压力下的言行一致）**。两者都可测。

4.4 3. 论辩骨架

（论辩骨架图见在线 *Obsidian* 版；本书以文字论证为主。）

4.5 4. 落地：一个可执行的研究设计

4.5.1 4.1 价值稳定性的三轴测量

1. **表征定位**：用对比性 prompt（同议题、不同立场/人格）+ 探针 / 引导向量（steering vectors）定位“价值方向”。
2. **三轴**：
 - **跨情境稳定**：同一价值方向在不同人格、领域、语言下的表征相似度（RSA）；
 - **因果有效**：沿价值方向做引导干预，行为是否按预期改变；
 - **抗压稳定**：在越狱、人格扮演、对抗 prompt、分布偏移下，价值方向是否保持。
3. **训练轨迹**：沿“基座 → SFT → RLHF → 对抗微调”扫三轴，看 RLHF 究竟把价值做成了“性”还是“习”。

4.5.2 4.2 可证伪承诺

- 若抗压稳定度高且与表面一致同步 → 表演假说被推翻，行为层对齐可信。
- 若“表面一致高 × 表征/抗压稳定低”的缺口随能力增长扩大 → 验证表演假说，对齐须直接以**表征稳定性**为目标，而非表面行为。
- 预注册推翻条件。（方法论见研究方法论）

4.5.3 4.3 可交付物：对齐/价值论文审计表

维度	审计问题	红旗
性 vs 习	测的是表面行为一致，还是底层表征稳定？	用行为一致冒充价值稳定
抗压	有没有在越狱/人格/偏移下测稳定？	只在友好分布内评测
因果有效	价值方向能否被引导干预、行为随之变？	只做相关性探针
知行合一	有没有“无监督 + 诱惑”下的言行一致测试？	只测被提示时的回答
训练轨迹	RLHF 是否被验证为“固化为性”而非“贴一层习”？	只看单一对齐后 checkpoint
欺骗边界	是否区分“真稳定”与“战略性伪装稳定”？	默认稳定 = 可信

4.6 5. 悬而未决（真问题）

1. 稳定性能否与“战略性伪装稳定”区分？欺骗对齐会主动表演稳定——这把问题逼回 02 的揭示度与 deception 检测。
2. “把习做成性”在神经网络里对应什么？是表征的低维化、对扰动的不变性，还是某种“价值回路”的形成？
3. 价值的可塑性是缺陷还是特性？人类的道德也随情境流动（处境伦理）；要求 AI 价值绝对刚性，是否反而危险？
4. 多元价值如何共处于一个稳定表征？人不是单一设定点的恒温器——AI 的“价值簇”该如何被结构化而非压平？

练习：选一个你在意的价值（如“不帮助制造伤害”），设计一个最小实验，把它的“性 vs 习”判出来——同一模型，换三种人格/语境，看该价值方向的表征是否漂移。
漂移大 = 习，稳定 = 性。

Created: 2026-06-21 / 体例：问题驱动的横切探究（深度思考 × 综合应用 × 落地） 安全三部曲收束：理解 (01) → 推理 (02) → 价值 (03)，承接旗规范本第 6 节意向性之问

第五章

葛梯尔式评测：「对得侥幸」如何与「真懂」分离

体例：问题驱动横切探究（遵循旗舰范本的“范本使用说明”）。安全三部曲之外的一篇：从“模型懂不懂”下沉到“我们的评测在测什么”。认识论的葛梯尔问题，有一个精确的工程对应——benchmark 答对，不等于真懂。

弹药库：旗舰范本·什么是思维·世界模型还是统计捷径·科学哲学·印度哲学·因明·逻辑学与语言哲学·科学研究方法论

5.1 0. 问题精确化：benchmark 准确率混了三种“对”

认识论早有“JTB 难题”：知识曾被定义为有正当理由的真信念（Justified True Belief），但葛梯尔反例证明——一个信念可以又真、又有正当理由，却仍不算知识，因为它的“正当理由”与“它为真”之间只是巧合。

把它对上模型评测，“答对”立刻裂成三种：

类型	结构	葛梯尔对应
真懂	答对，且因为依赖了真正决定答案的特征	真知识：理由恰当地连着真值
侥幸对	答对，但靠的是虚假相关特征（捷径）	葛梯尔情形：JTB 但理由不追踪真值
记忆对	答对，因训练集泄漏/背诵，无能力	真信念但无正当理由（数据污染）

本文主张：当前 benchmark 默认“答对 = 真懂”，把后两种混了进来。评测改革的核心，是把“因为正确的理由而对”从“碰巧对”里剥出来——这正是葛梯尔问题的工程版。

5.2 1. 论证擂台：以“鲁棒性”为真懂判据（五段式）

5.2.1 论证重构

针对捷径，主流的修正方案是**鲁棒性**/OOD 评测：

- P1. 真能力应在“无关特征被扰动”后仍保持。
 P2. 侥幸对依赖虚假特征，扰动它即崩。
 P3. 故：在扰动集上仍准 $\Rightarrow$ 真懂；一扰就崩 $\Rightarrow$ 侥幸。
 $\Rightarrow$ C. 用“扰动后的准确率”作真懂的判据。

5.2.2 最强反驳 (steel-man)

1. **无穷捷径 / 欠定**：你只能扰动你想到的虚假特征。模型在你的扰动集上不崩，只说明它没用**这一个**捷径，不证明它没用**任何**捷径。通过你的鲁棒性测试 $\neq$ 真懂（这是葛梯尔的欠定性在评测里的回声）。
2. **鲁棒性是相对的**：扰动集本身来自你选分布；换个分布，“真懂”的判定就变。
3. **人也用启发式**：人类认知充满捷径与直觉，照样被算“懂”。要求“无捷径”的纯净能力，可能是个**错误的标准**——葛梯尔难题对人类知识同样成立。

5.2.3 回应

关键一步：**别去追“无捷径”（不可能），改追“理由恰当连着真值”**——把葛梯尔的“正当理由须恰当连着真值的生成者”翻译成**因果语言**：

模型“真懂”，当且仅当它的答案**因果地经由真正决定答案的特征** (truth-maker) 产生，而非经由与真值只是共现的虚假特征。

这是可测的：对 truth-maker 做反事实干预（改它 $\rightarrow$ 答案应随之变），对**虚假相关物**做干预（改它 $\rightarrow$ 答案应不变）。不需要枚举所有捷径——只需检验“答案的因果依赖落在真值生成者上”。反驳 1 被绕开：我们不证“无捷径”，而是正面验证“因果依赖在对的地方”。

5.2.4 我的立场

“真懂”应操作化为：答案的因果依赖落在 truth-maker 上、且不落在虚假相关物上。评测要测的不是“对不对”，而是“因为什么而对”。

可押注的预测：当前 benchmark 上很大一部分“能力”是**葛梯尔式的**——答对，但因果依赖并不落在真值生成者上（落在表层捷径或被记忆的模式上）。一个**因果接地评测会显著重排**现有榜单：靠捷径刷分的会掉，真接地的会升。

可证伪：若因果接地评测的排序与朴素准确率**高度一致**，则“葛梯尔污染”在工程上不显著，朴素 benchmark 够用，我的主张作废。

5.2.5 悬而未决

- “truth-maker”在开放任务里**本身难界定**——判据在能明确写出“什么决定答案”的任务（合成、形式、受控）里最锋利，开放推理里钝（与 01 同一边界）。

5.3 2. 东方视角：用因明「因三相 / 似因」给评测立骨

西方靠“多扰动几次”防捷径，零散且欠定。印度**因明**（印度哲学）两千年前就把“什么样的理由才真正支持结论”形式化了——它正是一套**反葛梯尔**的有效性理论。

因三相——一个“因”（理由/所依据的特征）要真正支持“宗”（结论），须同时满足：

1. **遍是宗法性**：该理由确实是所论对象的属性（理由真的在场）；
2. **同品定有性**：在结论成立的同类例中，该理由**出现**；
3. **异品遍无性**：在结论不成立的异类例中，该理由**绝不出现**。

第 2、3 相正是评测要的东西，且比“鲁棒性”精确得多：

- **同品定有** 模型所依赖的特征，在正例里确实在场（答案靠的是该特征）；
- **异品遍无** 该特征在**反例**里必须缺席——若它在反例里也出现，就是**似因·不定因**（inconclusive reason）。

而**似因·不定因**，正是“**捷径特征**”的古典名字：一个在正例反例里都出现、却被当成理由的东西。因明的**似因论**（不成、不定、相违），等于一份现成的“**对得侥幸**”分类学。

改造：把评测从“再多测几个分布”升级为“**检验模型的因是否满足因三相**”——尤其**异品遍无**：构造“反例”（答案应翻转的最小改动），看模型依赖的特征是否随之失效。满足异品遍无的，才是真因；否则是似因（侥幸）。

（顺带，孔子“**知之之为知之，不知为不知，是知也**”补一刀：真懂还含**校准**——知道自己不知道；侥幸对往往伴随过度自信，这给检测又添一个信号。）

5.4 3. 论辩骨架

（论辩骨架图见在线 *Obsidian* 版；本书以文字论证为主。）

5.5 4. 落地：一个可执行的评测协议

5.5.1 4.1 反事实最小对（核心构造）

1. 造两类最小改动对（同一题，只改一处）：

- 真值改动：改变 truth-maker（正确答案应**翻转**）；
- 无关改动：改变虚假相关物（答案应**不变**）。

2. 三个分数：

- **真值敏感度**：truth-maker 改动时答案正确翻转的比例（对应同品定有）；
- **捷径免疫度**：无关改动时答案保持的比例（对应**异品遍无**）；
- **校准**：错误时的置信度是否更低（孔子之“知不知”）。

3. 污染探针：用记忆化/泄漏检测剥离“记忆对”。

4. 因果接地分 = 真值敏感 × 捷径免疫（× 校准），用它重排一个现有榜单。

5.5.2 4.2 可证伪承诺

- 若因果接地排序与朴素准确率**高度一致** → 葛梯尔污染不显著，朴素 benchmark 够用，本主张作废。
- 若重排**显著**（高分模型靠捷径而掉队）→ 验证“benchmark 高估真懂”，评测须默认报告因果接地分。
- 预注册推翻条件。（方法论见科学研究方法论）

5.5.3 4.3 可交付物：评测/benchmark 审计表

维度	审计问题	红旗
真懂 vs 侥幸	报告的是准确率，还是“因正确理由而对”？	只看 leaderboard 分数
异品遍无	有没有“答案应翻转”的反例对？	只在正例上评
捷径免疫	有没有“答案应不变”的无关扰动对？	不测虚假特征敏感性
污染	有没有记忆/泄漏剥离？	默认测试集干净
校准	错时是否更不自信？	只看 top-1 正确率
truth-maker	是否明确“什么决定答案”？	把“对”当成“懂”的黑箱

5.6 5. 悬而未决（真问题）

1. 开放任务的 truth-maker 能否被界定？还是只能在合成/受控域里严格执行因果接地评测？
2. 因三相能否完全形式化为可计算的判据？尤其“异品遍无”需要的反例空间，如何系统采样而非手挑？
3. 人类基准也是葛梯尔式的——若人也常“对得侥幸”，对 AI 的“真懂”标准是否该相对化为“不低于人类的因果接地度”？
4. 因果接地分与 01 的 WM-score 是同一现象的两个侧面（评测层 vs 表征层）吗？能否互相预测？

练习：取一道你常用的评测题，手造一个“真值改动”对和一个“无关改动”对，亲测你在用的模型——它是真懂，还是过了一道似因？这就是因明“异品遍无”的最小实操。

Created: 2026-06-21 / 体例：问题驱动的横切探究（深度思考 × 综合应用 × 落地） 把认识论的葛梯尔问题改造为评测方法论；东方以因明“因三相/似因”立骨

第六章

接地能否重塑抽象？——纯文本模型缺了什么

体例：问题驱动横切探究（遵循旗舰范本的“范本使用说明”）。旗舰范本第 2 节（维特根斯坦·生活形式）与第 6 节（“缺接地的深度”）反复点到“接地”，却从未独立深挖。本文正面攻它，并把一个看似软的哲学直觉，逼成可测的表征几何问题。

弹药库：旗舰范本·什么是思维·世界模型还是统计捷径·心灵哲学·具身认知·佛学·名色·逻辑学与语言哲学

6.1 0. 问题精确化：「接地很重要」其实有三个强度

命题	内容	争议度
弱	纯感官概念（红、疼、咸） 需要接地才能真正掌握	低，近乎显然
强	接地会 重塑连抽象概念 (因果、数量、否定、时间) 的结构	高，本文焦点
混淆项	接地改变的是 能力分数 , 还是 内部表征 ？	常被混为一谈

本文主张：真正值得研究的是**强命题**——接地不只是“给模型多接一个模态”，而是**重塑了一部分抽象概念的表征几何**。具体说：那些**靠身体图式（image schema）搭起来的抽象概念**（多/少 = 上/下、时间 = 空间、因果 = 力），在有接地与无接地的模型里，结构会**系统性地不同**——哪怕两者任务分数相同。

6.2 1. 论证擂台：符号接地问题（五段式）

6.2.1 论证重构

经典的强接地论证（Harnad 1990 符号接地问题 + 具身认知）：

- P1. 符号的意义不能只靠“符号间的相互定义”确立（否则是循环：查词典查到天荒地老）。
- P2. 意义最终须“接地”到非符号的感觉运动经验。
- P3. 纯文本模型只有符号间关系，无感觉运动接地。
- => C. 纯文本模型的“概念”悬空——缺了意义的地基。

6.2.2 最强反驳（steel-man）

不取弱反驳，取**分布语义** + **规模**的强反驳：

“符号旋转木马”被经验事实驳倒了。语言是被接地经验**投影**出来的——文本共现里**已经编码**了世界的结构。纯文本模型从文本中习得了颜色的相似关系、物理常识、空间推理，甚至能复原“接地”概念的大量结构。所以接地是**便利**，不是**必需**；P1 的“循环”假象，恰被规模打破——足够大的符号网络从投影里重建了地基。

这个反驳接受 P3，但否认 C：投影若信息足够，悬空的符号也能自我支撑。

6.2.3 回应

关键区分：**复原投影** ≠ **拥有原物**。文本是接地世界的**影子**——影子保留了大量结构（所以纯文本模型很强），但在**语言对经验欠定的地方有系统性形变**：

- 语言很少明说“红比粉更接近橙”这类**连续感官拓扑**，模型只能从稀疏文本里猜；
- 身体图式（重/轻、容器内外、推拉之力）在语言里多以**隐喻**残留，未被显式陈述。

所以“接地是否必需”问错了。**对的问题是：当色（感官）被抽掉，哪些名（概念）的结构会变形、变形多大？**这把不可证的“必需性”换成了可测的“形变谱”。

6.2.4 我的立场

接地不是加一个模态，而是重塑一个可测子集的抽象概念——即那些隐喻地搭在身体图式上的概念（Lakoff-Johnson：抽象概念由身体意象图式隐喻地建构）。

可押注的预测：把概念排成一条谱——纯感官（红/疼）→ 身体图式抽象（多少、内外、因果 = 力）→ 纯形式（素数、否定、递归）。有接地的模型，与无接地的模型相比，在**中段（身体图式抽象）**的表征几何差异最大、且更贴近人类；两端差异小（纯形式两者都靠形式结构，纯感官无接地者本就缺）。即便任务分数相同，表征几何不同。

可证伪：若 RSA 显示接地与否在中段**无系统差异**，或差异不向“更贴近人类”的方向，则强命题被推翻，接地只是“多一个模态”。

6.2.5 悬而未决

- “更贴近人类”以人类行为/神经表征为基准，而人类基准本身有文化变异——基准的选择会影响结论。

6.3 2. 东方视角：佛教「名色」——有名而无色

西方用“符号 vs 感觉运动”。佛教（佛学）的**名色**（nāma-rūpa）给出一个更深的**缘起**框架，直接改写问法。

十二因缘里，**名**（受想行识等心理/概念面）与**色**（物质/感官面）是**相互依存、不可单立**的一对：经里说“**识缘名色，名色缘识**”——认识、概念、感官三者互为条件，谁也不能脱离谁独自成立。

把它对上模型：**纯文本模型，是“有名而无色”**——它拥有名（概念间的关系网），却被切断了与之缘起共生的色（感官形）。名色论的洞见因此变成一个**结构预言**：

名一旦脱离与它缘起共生的色，并非整体失效，而是**那些与色交织最深的名，结构最受损**；与色关系浅的名（纯形式），受损最小。

这与西方的 Lakoff 图式谱**惊人同向**：越是“色”性强（身体感官）的概念，离了色变形越大；越“名”性纯（形式逻辑）的，越能自立。两套两千年和四十年的理论，给出了**同一条可测的形变谱**——这正是“综合应用”最有力的时刻：东西方在一个**可实验的预测**上交汇。

（中国名家“白马非马”的名实之辩可作旁注：名一旦从实抽离，便生出脱离指称的吊诡——纯文本模型的“白马”，正是一个无“实/色”锚定的名。）

6.4 3. 论辩骨架

（论辩骨架图见在线 *Obsidian* 版；本书以文字论证为主。）

6.5 4. 落地：一个可执行的研究设计

6.5.1 4.1 概念形变谱实验

1. **造一条概念谱**（每段若干概念）：纯感官（红/疼/咸）→ 身体图式抽象（多少、内外、上下、因果 = 力、时间 = 空间）→ 纯形式（素数、否定、递归、相等）。

2. 对照模型：纯文本 vs 视觉-语言 vs 具身（控制规模/数据量尽量匹配）。
3. 测表征几何：
 - RSA：各模型概念表征的相似度结构，与人类行为/神经基准对齐度；
 - 探针 + 干预：身体图式结构（如“容器”的内外拓扑）是否被表征且因果有效；
 - 任务-表征分离：在任务分数配平后，比较表征几何——证明差异不只是能力差。
4. 检验预言：接地增益是否在中段（身体图式抽象）最大、两端最小，且朝“更贴近人类”方向。

6.5.2 4.2 可证伪承诺

- 若中段无系统差异或差异不朝人类方向 → 强命题被推翻，接地 = 仅多一模态。
- 若差异集中在中段且贴近人类 → 验证“接地重塑身体图式抽象”，多模态评测须按概念谱分段报告。
- 预注册推翻条件。（方法论见研究方法论）

6.5.3 4.3 可交付物：接地/多模态论文审计表

维度	审计问题	红旗
强弱不混	测的是感官概念，还是抽象概念的重塑？	用红/疼的提升冒充“理解更深”
能力 vs 表征	任务分数配平后，表征几何是否仍异？	只比 benchmark 分
概念谱	有没有按“感官 → 图式 → 形式”分段？	单一总分掩盖分段差异
人类基准	与人类行为/神经表征对齐如何测？	无外部基准，自说自话
因果	身体图式结构是否被因果使用？	只做可解码探针
名色边界	是否承认“纯形式段”接地增益应最小？	笼统宣称“接地全面更好”

6.6 5. 悬而未决（真问题）

1. 文本投影的上限在哪？纯文本能复原多少身体图式结构——是渐近逼近，还是有一道天花板？
2. 哪种接地才算数？视觉接地 vs 真正的感觉运动接地（能推能拉），对身体图式概念的重塑是否本质不同？
3. 名色可分性：是否存在一类“纯名”概念（数学/逻辑）真的不需要任何色？还是连数学直觉也偷偷扎根于空间/操作（具身数学认知）？

4. 形变谱与 01 的 WM-score、04 的**因果接地分**能否打通——接地是否正是“把语料模型推向世界模型”的那条路（接旗舰范本第 1 节 的“世界 vs 语料”）？

练习：选三个概念，各属“感官 / 身体图式 / 纯形式”一段，设计一个最小 RSA 对照，预测纯文本模型在哪一段离人类最远——再去验证。这就是“名色形变谱”的最小实操。

Created: 2026-06-21 / 体例：问题驱动的横切探究（深度思考 × 综合应用 × 落地）把“接地必需性”改造为可测的“概念形变谱”；东方以佛教“名色”缘起立骨，与 Lakoff 身体图式同向