

具身智能大模型

面试题库与精讲

Embodied AI & VLA Interview Handbook

12 大模块 • 78 道高频题 • 数理推导 + PyTorch 代码
从基础概念到 SOTA (RT / OpenVLA / π_0 / RDT)

整理: _____

【免费试读版】

目 录

1 具身智能大模型·面试题库总览	3
1.1 模块地图	3
1.2 M1·具身智能基础概念	4
1.3 M2·多模态大模型基础 (VLM)	4
1.4 M3·VLA 模型 (Vision-Language-Action)	4
1.5 M4·模仿学习与策略学习	5
1.6 M5·强化学习在具身	5
1.7 M6·世界模型与预测	5
1.8 M7·数据、仿真与 Sim2Real	5
1.9 M8·感知与 3D 表示	6
1.10 M9·规划、控制与系统	6
1.11 M10·经典论文与 SOTA (要能讲清贡献与局限)	6
1.12 M11·工程与部署	6
1.13 M12·开放题与项目面	7
1.14 学习路径建议	7
2 M1·具身智能基础概念—逐题精讲	8
2.1 Q1 ★ 什么是具身智能? 与传统机器人控制、纯语言大模型的本质区别?	8
2.1.1 一句话定义	8
2.1.2 三方对比 (面试可直接背这张表)	8
2.1.3 本质区分的三个要点	8
2.2 Q2 ★ ”具身” 为什么重要? 从感知-行动闭环解释	9
2.3 Q3 摩拉维克悖论 (Moravec's Paradox)	9
2.4 Q4 符号主义 / 联结主义 / 具身认知三条路线	9
2.5 Q5 ★ 大模型时代, 具身相比”互联网 AI” 的独特挑战	9
2.6 Q6 一个完整具身智能体的 pipeline	10
2.7 Q7 ◆ 你认为”通用机器人” 最大的瓶颈是什么? (开放题示范答法)	10
2.7.1 本模块自测 (合上文档能答出来吗)	10
3 M3·VLA 模型 (Vision-Language-Action) —逐题精讲	11
3.1 Q15 ★ 什么是 VLA 模型? 输入输出与典型架构	11
3.2 Q16 ★★ 机器人动作如何被模型表示? 三条路线 (最核心)	11

3.2.1	路线 A: 动作离散化为 token (autoregressive)	11
3.2.2	路线 B: 直接回归连续值 (regression)	11
3.2.3	路线 C: 生成式 head (diffusion / flow matching)	12
3.3	Q17 ★ RT-2 的核心思想	12
3.4	Q18 ★ OpenVLA 相比 RT-2 的改进 / 为何能开源复现	12
3.5	Q19 ★ action chunking 是什么? 为什么有用	13
3.6	Q20 ★ VLA 动作频率受限于什么? 慢推理与高频控制如何协调	13
3.7	Q21 ★ π_0 (Pi-Zero) 用 flow matching 输出动作的优势	13
3.8	Q22 ◆ 如何设计 VLA 实现 zero-shot 泛化 (开放题)	14
3.8.1	本模块自测 (重点中的重点)	14

1 具身智能大模型 · 面试题库总览

方向: *Embodied AI* + 大模型 (VLA / 多模态 / 机器人基础模型) 用法: 先通览本题库, 标记薄弱模块; 再进入「逐题精讲」逐个攻克。标记: ★ 高频必考 | ☆ 进阶/加分 | ◆ 开放/研究思维题

模块地图

编号	模块	核心考点	精讲文件
M1	具身智能基础概念	定义、范式、与传统机器人/纯 LLM 的区别	逐 题 精 讲/01-基 础 概 念.md
M2	多模态大模型基础 (VLM)	视觉编码、对齐、注意力、tokenizer	逐 题 精 讲/02-多 模 态 基 础.md
M3	VLA 模型	架构、action head、动作离散化	逐 题 精 讲/03-VLA 模 型.md
M4	模仿学习与策略	BC、ACT、Diffusion Policy	逐题精讲/04-模仿学习与策略.md
M5	强化学习在具身	RLHF/在线 RL、sim 中的 RL、奖励设计	逐 题 精 讲/05-强 化 学 习.md
M6	世界模型与预测	world model、video prediction、规划	逐 题 精 讲/06-世 界 模 型.md
M7	数据、仿真与 Sim2Real	遥操作、数据飞轮、域随机化	逐 题 精 讲/07-数 据 与 仿 真.md
M8	感知与 3D 表示	点云、NeRF/3DGS、空间表征	逐 题 精 讲/08-感 知 与 3D.md
M9	规划、控制与系统	分层架构、实时性、安全	逐题精讲/09-规划控制系统.md
M10	经典论文与 SOTA	RT 系列、OpenVLA、 π^0 、RDT、Octo	逐 题 精 讲/10-经 典 论 文 SOTA.md
M11	工程与部署	推理加速、边缘部署、频率	逐 题 精 讲/11-工 程 部 署.md
M12	开放题与项目面	研究品味、项目深挖、反问	逐题精讲/12-开放题与项目面.md
附 A	数学基础速查	attention/对 比/扩 散/flow/VAE/RL/旋 转	深度补充/A-数学基础速查.md
附 B	核心算法代码	PyTorch 手写各核心 loss 与策略	深度补充/B-核心算法代码.md

深度补充是为了应对”推导一下””手写个 $loss$ ”类深挖，建议在过完对应模块后配套学。例：学完 $M_4(Diffusion Policy)$ → 看附 A3 扩散数学 + 附 B3 代码。

M1 · 具身智能基础概念

1. ★ 什么是具身智能 (Embodied AI)? 它和传统机器人控制、和纯语言大模型相比，本质区别是什么?
2. ★ ”具身”为什么重要? 请从感知-行动闭环 (perception-action loop) 角度解释。
3. 摩拉维克悖论 (Moravec's Paradox) 是什么? 它对具身智能意味着什么?
4. 符号主义、联结主义、具身认知三条路线的区别? 具身智能属于哪一脉?
5. ★ 大模型时代，具身智能相比”互联网 AI (Internet AI)”面临的独特挑战有哪些? (数据、实时、安全、长尾)
6. 一个完整的具身智能体包含哪些模块? 请画出 sense→think→act 的 pipeline。
7. ◆ 你认为”通用机器人脑”目前最大的瓶颈是什么? 为什么?

M2 · 多模态大模型基础 (VLM)

1. ★ 视觉信息如何输入到大模型? 对比 CLIP、ViT-patch、Q-Former、cross-attention 几种方式。
2. ★ CLIP 的训练目标是什么? 对比学习 (contrastive) 为什么对具身有用?
3. 主流 VLM (LLaVA / BLIP-2 / Flamingo / Qwen-VL) 的视觉-语言对齐方式分别是怎样的?
4. 什么是 visual token? 图像 token 数量过多会带来什么问题，如何压缩?
5. ★ 为什么很多 VLA 直接复用预训练 VLM 作为 backbone? 带来什么先验?
6. 多模态对齐中的”模态鸿沟 (modality gap)”指什么?
7. ◆ 视频理解相比图像理解，对具身有什么额外价值和难点?

M3 · VLA 模型 (Vision-Language-Action)

1. ★ 什么是 VLA 模型? 输入输出分别是什么? 请描述其典型架构。
2. ★ 机器人动作 (连续、高维、高频) 如何被语言模型表示? 对比”动作离散化为 token” vs ”回归连续值” vs ”diffusion/flow head”。
3. ★ RT-2 的核心思想是什么? 它如何把动作变成 token 接到 VLM 上?
4. OpenVLA 相比 RT-2 做了哪些改进? 为什么能开源复现?
5. ★ action chunking 是什么? 为什么能缓解误差累积和抖动?
6. VLA 的动作输出频率通常受什么限制? 大模型推理慢如何与高频控制 (如 1kHz) 协调?
7. ★ π_0 (Pi-Zero) 用 flow matching 输出动作，相比离散 token 有什么优势?
8. ◆ 你会如何设计一个 VLA，使它能 zero-shot 泛化到没见过的物体/指令?

M4 · 模仿学习与策略学习

1. ★ 行为克隆 (BC) 的基本原理? 它最大的问题是什么 (distribution shift / compounding error)?
2. ★ DAgger 如何缓解 BC 的分布偏移? 代价是什么?
3. ★ Diffusion Policy 的核心思想? 为什么用扩散模型建模动作比直接回归好? (多模态分布)
4. ★ ACT (Action Chunking with Transformers) 的关键设计? CVAE 在其中起什么作用?
5. 模仿学习中”多模态动作分布”指什么? 为什么 MSE 回归会导致”取平均”失败?
6. ★ 如何评估一个模仿学习策略的好坏? 仿真成功率和真机成功率为何常常不一致?
7. ◆ 只有少量人类示范数据, 你如何提升策略的鲁棒性?

M5 · 强化学习在具身

1. ★ 强化学习和模仿学习在具身任务中各自的优劣? 什么时候该用哪个?
2. on-policy (PPO) vs off-policy (SAC) 在机器人中的取舍?
3. ★ 稀疏奖励问题如何解决? (reward shaping、HER、curriculum、demonstration)
4. ★ 为什么真机上做 RL 很难? sim 中训练再迁移的主要障碍是什么?
5. RLHF 的思想能否迁移到具身? 如何用偏好/人类反馈优化机器人策略?
6. ◆ 给定一个”把杯子放到架子上”的任务, 你如何设计奖励函数? 会踩哪些坑?

M6 · 世界模型与预测

1. ★ 什么是世界模型 (World Model)? 它在具身智能中扮演什么角色?
2. 基于模型的 RL (MBRL) 相比 model-free 的优势与风险?
3. ★ 用视频生成模型 (如 Sora 类) 做世界模型/策略, 思路是什么? 有什么局限?
4. Dreamer 系列的核心机制 (latent imagination) 是什么?
5. ◆ ”预测下一帧”和”预测下一个动作”哪个对机器人更本质? 谈谈你的看法。

M7 · 数据、仿真与 Sim2Real

1. ★ 具身智能的数据从哪来? 对比遥操作、人类视频、仿真、自主采集的优缺点。
2. ★ 什么是 Sim2Real gap? 主要来源有哪些 (动力学、渲染、传感器噪声)?
3. ★ 域随机化 (Domain Randomization) 的原理? 如何选择随机化的维度?
4. Open X-Embodiment 数据集的意义是什么? 跨本体 (cross-embodiment) 训练的难点?
5. ★ 数据飞轮 (data flywheel) 在机器人公司里怎么转起来?
6. 遥操作数据的常见质量问题有哪些? 如何清洗?
7. ◆ 给你 100 台机器人和有限预算, 你如何设计数据采集策略最大化策略性能?

M8 · 感知与 3D 表示

1. ★ 机器人为什么常需要 3D 表示而非纯 2D? 点云、深度图、voxel、3DGS 各自适用场景?
2. 6-DoF 抓取位姿估计的常见做法?
3. ★ NeRF 和 3D Gaussian Splatting 在机器人里的用途 (重建、仿真资产、表征)?
4. 如何把空间/几何信息注入到 VLA 大模型里?
5. ◆ 仅靠 RGB 单目能否做好操作任务? 谈深度信息的必要性。

M9 · 规划、控制与系统

1. ★ 分层架构 (high-level 任务规划 + low-level 控制) 的优劣? 端到端 vs 分层之争。
2. ★ LLM 做任务规划 (task planning) 的典型范式? (SayCan、Code as Policies、ReAct)
3. SayCan 的 affordance grounding 思想是什么? 解决了 LLM 的什么问题?
4. ★ 长程任务 (long-horizon) 为什么难? 如何做子目标分解?
5. 控制频率、感知频率、规划频率不一致时系统如何协调?
6. ◆ 端到端 VLA 和“LLM 规划 + 技能库”两条路线, 你赌哪个能走向通用? 为什么?

M10 · 经典论文与 SOTA (要能讲清贡献与局限)

1. ★ RT-1 $\rightarrow$ RT-2 $\rightarrow$ RT-X 的演进脉络, 每一步解决了什么?
2. ★ OpenVLA: 架构、训练数据、关键结论。
3. ★ $\pi_0 / \pi_{0.5}$ (Physical Intelligence): flow matching action expert 的设计。
4. RDT-1B (清华): 扩散 + 大模型, 双臂操作的贡献?
5. Octo: 通用机器人策略 transformer 的设计取舍?
6. ★ Gemini Robotics / GR00T (NVIDIA) / Helix (Figure) 你了解多少? 各自卖点?
7. ★ Diffusion Policy、ACT 这两篇“操作策略经典”必须能默写架构。
8. ◆ 选一篇你最近读过的具身论文, 讲清 motivation、方法、实验、你的批判。

M11 · 工程与部署

1. ★ 大模型 VLA 推理慢, 部署到机器人上有哪些加速手段? (量化、蒸馏、缓存、异步)
2. action chunking / receding horizon 如何在工程上平衡延迟与平滑?
3. ★ 边缘设备 (Jetson 等) 算力受限, 如何做模型裁剪与调度?
4. 实时控制对延迟和抖动 (jitter) 的要求? 大模型如何不阻塞控制回路?
5. ◆ 你会如何搭一套从数据采集 $\rightarrow$ 训练 $\rightarrow$ 评测 $\rightarrow$ 部署的完整 MLOps 闭环?

M12 · 开放题与项目面

1. ★ 介绍一个你做过的具身/机器人/大模型项目：问题、方法、你的贡献、结果、复盘。
2. ★ 你这个方法相比 baseline 好在哪？如果再给你两周你会怎么改进？
3. ★ 你怎么看具身智能未来 3 年的技术路线？哪些是泡沫，哪些是真趋势？
4. 数据 vs 算法 vs 算力，你认为当前具身的瓶颈主要在哪？
5. ♦ Scaling law 在具身上成立吗？数据规模上去性能就一定上去吗？
6. ♦ 如果让你从零带队做一个家庭服务机器人的” 大脑”，技术路线怎么定？
7. (反问环节) 你会问面试官/团队哪些问题来判断这个岗位值不值得去？

学习路径建议

- 第 1 轮 (建立框架)：M1 → M2 → M3，先把” 具身 + 大模型” 的主干打通。
- 第 2 轮 (策略核心)：M4 → M5 → M6，吃透策略学习三大流派。
- 第 3 轮 (数据与系统)：M7 → M8 → M9，理解落地工程。
- 第 4 轮 (冲刺)：M10 论文精读 + M11 工程 + M12 模拟面。

进度记录见同目录 99-进度追踪.md (可选)。

2 M1 • 具身智能基础概念—逐题精讲

目标：把”具身 + 大模型”的底层叙事讲清楚，面试一开口就有框架感。

Q1 ★ 什么是具身智能？与传统机器人控制、纯语言大模型的本质区别？

一句话定义

具身智能（Embodied AI）= 智能体**拥有物理身体**，通过**感知-行动闭环**与**真实（或仿真）环境**持续交互、并在交互中学习的智能。智能不是”被灌进去的知识”，而是在**身体与环境耦合中涌现**出来的。

三方对比（面试可直接背这张表）

维度	传统机器人控制	纯语言大模型 (LLM)	具身智能大模型
智能来源	人工建模 + 控制律	海量文本统计规律	多模态交互数据中学习
输入	结构化传感器	文本/图像	视觉 + 语言 + 本体感知 (proprioception)
输出	预设控制指令	文本 token	物理动作 (连续/高维/高频)
环境耦合	有，但靠人工建模	无（开环、无身体）	有，闭环、可试错
泛化	弱，换场景重调	语义泛化强	目标：语义泛化 + 物理泛化
失败代价	实时安全关键	仅输出错误	可能损坏硬件/伤人 ，不可回退

本质区分的三个要点

- 输出空间不同**：LLM 输出离散 token，机器人要输出**连续、高维、带时序、有物理约束**的动作。这是 VLA 最核心的难点。
- 闭环 vs 开环**：LLM 是”问一句答一句”的开环；具身是”动作改变世界、世界又反馈”的闭环，误差会**累积**（compounding error）。
- 数据性质不同**：文本是”免费”的互联网数据；具身数据要靠遥操作/仿真**昂贵采集**，且存在 Sim2Real gap。

加分句：”纯 LLM 是 *Internet AI*，知道‘世界是什么样’；具身智能要回答‘我该怎么动’，需要把语义 *grounding* 到物理动作上。”

Q2 ★ ”具身”为什么重要？从感知-行动闭环解释

- **认知科学依据**：具身认知（Embodied Cognition）认为，智能离不开身体——概念的意义部分来自身体经验（如”重””上下”源于身体感受）。
- **闭环的价值**：感知 → 决策 → 行动 → 改变环境 → 新感知。机器人通过”动”来主动获取信息（active perception，如换个角度看遮挡物），并即时纠错。
- **对比开环**：开环系统一步错步步错；闭环可以根据反馈实时修正，是应对真实世界**不确定性**的根本机制。

Q3 摩拉维克悖论（Moravec’s Paradox）

内容：对人类很难的事（下棋、证明定理）对机器很容易；对人类很容易的事（抓取、行走、感知）对机器极难。

原因：高级推理是近期演化、可符号化的；而感知运动能力是亿万年演化打磨、高度并行、难以形式化的”隐性智能”。

对具身的意味：大模型解决了”高级认知”（语言、推理）后，**真正的硬骨头恰恰是底层的感知-操作-运动控制**——这正是具身智能要啃的部分。这也是为什么”会聊天的 AI”早就有了，”会叠衣服的机器人”还很难。

Q4 符号主义 / 联结主义 / 具身认知三条路线


路线	主张	代表	局限
符号主义 (GOF AI)	智能 = 符号操作 + 逻辑推理	专家系统、规划	脆弱、难处理感知
联结主义	智能 = 神经网络分布式表示	深度学习、大模型	黑箱、需大数据
具身认知	智能根植于身体与环境交互	Brooks 的行为机器人	难规模化、缺高层认知

具身智能大模型本质是**联结主义（大模型）+ 具身认知（身体闭环）**的融合，并常借符号主义做高层任务规划（如 LLM planner）。

Q5 ★ 大模型时代，具身相比”互联网 AI”的独特挑战

1. **数据稀缺且昂贵**：没有”机器人版互联网”，遥操作一条轨迹成本高。
2. **实时性**：控制回路要几十 ~ 上千 Hz，大模型推理慢，存在频率鸿沟。
3. **安全不可逆**：物理世界试错可能损坏硬件或伤人，不能像聊天那样”重来”。
4. **长尾与泛化**：真实世界物体/场景/光照无穷组合，分布外（OOD）样本是常态。
5. **本体异构**：不同机器人自由度/形态不同（cross-embodiment），策略难直接迁移。
6. **评测难**：真机评测慢、贵、难复现，sim 与真机成功率常不一致。

Q6 一个完整具身智能体的 pipeline



- **Sense**: 多模态传感 → 编码 (ViT/点云网络)。
- **Think**: 状态估计、世界模型预测、LLM 高层规划、策略输出动作。
- **Act**: 低层控制器 (PD/MPC/力控) 执行, 结果反馈回感知, 闭环。

端到端 VLA 把 "Think + 部分 Act" 压进一个大模型; 分层架构则显式拆分。两条路线见 M9。

Q7 ◆ 你认为"通用机器人脑"最大的瓶颈是什么? (开放题示范答法)

没有标准答案, 关键是有框架、有取舍、有自己的判断。一个稳妥的结构化回答:

"我认为当前主瓶颈是数据, 其次是评测与泛化的闭环。- 数据: 大模型在 NLP/CV 成功靠互联网级数据, 但机器人没有等价数据源, 遥操作成本高、覆盖窄, 这直接卡住了 *scaling*。- 但我不认为只堆数据就够: 还需要 *Sim2Real*、*cross-embodiment* 来放大数据价值, 需要更好的动作表示 (*diffusion/flow*) 来吃下多模态数据, 需要可靠真机评测来形成 *data flywheel*。- 算法和算力相对不是首要瓶颈——架构上 VLA 已收敛, 算力可堆。所以我会赌'数据 + 评测闭环'是未来两年的主战场。"

这样回答展示了: 知道 *scaling law*、知道数据/算法/算力三要素、有自己的赌注且能自治。

本模块自测 (合上文档能答出来吗)

自测清单

- ☐ 用一句话区分 LLM 和 VLA 的输出空间
- ☐ 摩拉维克悖论 + 对具身的含义
- ☐ 具身相比互联网 AI 的 3 个独特挑战
- ☐ 画出 sense-think-act 闭环
- ☐ 对"最大瓶颈"给出有取舍的开放回答

3 M3 • VLA 模型 (Vision-Language-Action) — 逐题精讲

整个面试的核心模块。VLA = 看 (Vision) + 懂 (Language) + 动 (Action)，把多模态大模型的语义能力接到机器人动作上。必须能默写架构、讲清“动作怎么表示”的三条路线。

Q15 ★ 什么是 VLA 模型？输入输出与典型架构

- 定义：Vision-Language-Action 模型，输入图像观测 + 语言指令 (+ 本体状态)，输出机器人动作的端到端大模型。
- 输入：
 - 视觉：一或多路 RGB(-D) 相机
 - 语言：自然语言指令 (“把可乐递给我”)
 - 本体感知 (proprioception)：关节角、夹爪状态 (可选)
- 输出：动作，通常是末端执行器位姿增量 $\Delta(x,y,z,roll,pitch,yaw)$ + 夹爪开合，或关节空间动作。
- 典型架构：

```
图像 - 视觉编码器(ViT/CLIP) --+
                                +- 大模型 Transformer - Action Head - 动作
指令 - 文本 tokenizer -----+      (三种路线见Q16)
本体状态 - (投影) -----+
```

本质：复用预训练 VLM 的语义理解 + 一个动作输出模块，用机器人数据微调“语义 → 动作”映射。

Q16 ★★ 机器人动作如何被模型表示？三条路线（最核心）

动作的难点：连续、高维、高频、多模态分布。三种主流表示：

路线 A：动作离散化为 token (autoregressive)

- 做法：把每个动作维度分箱 (binning) 成离散 token (如 256 个 bin)，像生成文字一样自回归预测动作 token。
- 代表：RT-1, RT-2, OpenVLA。
- 优点：完美复用 LLM 架构和词表，能直接接 VLM。
- 缺点：离散化有量化误差；自回归逐维生成慢；难表达精细连续控制。

路线 B：直接回归连续值 (regression)

- 做法：MLP head 直接输出连续动作向量，用 MSE/L1 监督。

- 优点：简单、快。
- 缺点：MSE 回归会对多模态动作“取平均”（见 Q27），遇到“可以左绕也可以右绕”时输出中间的错误动作。

路线 C：生成式 head (diffusion / flow matching)

- 做法：用扩散模型或 flow matching 把动作当作分布来采样生成。
- 代表：Diffusion Policy, π_0 (flow matching), RDT。
- 优点：天然建模多模态动作分布；动作平滑、精度高。
- 缺点：采样需多步迭代 (diffusion)，推理较慢 (flow matching 改善了这点)。

面试金句：“动作离散化让我们能复用 LLM，但牺牲精度和速度；diffusion/flow 能建模多模态分布、精度高，是当前 SOTA 操作策略的主流。”

Q17 ★ RT-2 的核心思想

- 一句话：把机器人动作编码成 token，当成一种“外语”，让预训练的视觉-语言模型 (PaLI-X/PaLM-E) 像输出文本一样输出动作 token，从而把互联网级的视觉语言知识迁移到机器人控制。
- 关键做法：
- 动作离散成 256 个 bin，占用文本 token 词表中的一些 token id。
- co-fine-tuning：同时用网络图文数据 + 机器人数据训练，保住语义泛化。
- 重要结论：涌现出语义泛化能力——能听懂“把草莓放进正确的碗”“拿起灭绝动物的玩具（恐龙）”这类需要常识推理的新指令。
- 局限：闭源、巨大、推理慢、高频控制难。

Q18 ★ OpenVLA 相比 RT-2 的改进 / 为何能开源复现

- 背景：RT-2 闭源、超大。OpenVLA (7B) 做了开源、可复现版本。
- 关键设计：
- Backbone：Prismatic VLM (SigLIP + DINOv2 双视觉编码器 + Llama2-7B)，双编码器兼顾语义和空间细节。
- 动作仍走离散化 token 自回归。
- 在 Open X-Embodiment (97 万 + 轨迹) 上训练，跨本体。
- 结论：7B 模型超过 55B 的 RT-2-X；支持 LoRA 高效微调和量化部署。
- 意义：把 VLA 平民化，成了学术界最常用的 VLA baseline。

Q19 ★ action chunking 是什么？为什么有用

- 定义：一次预测未来一段连续动作序列（一个 chunk，如未来 H 步），而不是只预测下一步。
 - 为什么有用：
 - 缓解误差累积：减少决策次数 → 减少 compounding error。
 - 减少抖动、动作更平滑：连贯输出一段轨迹。
 - 应对非马尔可夫/时序依赖，处理人类示范中的停顿和多模态。
 - 降低对大模型的调用频率：一次推理管 H 步，缓解”大模型慢 vs 控制要快”的矛盾。
 - 配套技术：temporal ensemble（ACT 提出）——对重叠时间步的多次预测做加权平均，进一步平滑。
 - 出处：ACT 论文提出，现已成 VLA/Diffusion Policy 标配。
-

Q20 ★ VLA 动作频率受限于什么？慢推理与高频控制如何协调

- 瓶颈：大模型一次前向几十 ~ 几百 ms，输出频率可能只有几 ~ 几十 Hz，而底层力控/电机要几百 ~ 1kHz。
 - 协调手段：
 - action chunking：一次出一段，低频规划 + 高频回放。
 - 分层（hierarchical）：大模型出子目标/中层动作（低频），低层控制器（MPC/PD）做高频跟踪。 $\pi 0.5$ 、Helix 都是这种 system1/system2 思路。
 - 异步执行：大模型异步推理，控制器持续运行不阻塞。
 - 推理加速：量化、蒸馏、flow matching 减少采样步数。
-

Q21 ★ $\pi 0$ (Pi-Zero) 用 flow matching 输出动作的优势

- 背景：Physical Intelligence 的 $\pi 0$ 。VLM backbone（PaliGemma）+ 独立的 action expert，用 flow matching 生成连续动作 chunk。
 - flow matching vs 离散 token：
 - 输出连续高频动作（50Hz），适合灵巧操作（叠衣服、打包）。
 - 比 diffusion 采样步数少、推理更快。
 - 天然建模多模态分布，动作平滑精确。
 - vs 回归：避免 MSE 取平均问题。
 - 是”VLM 语义 + 生成式连续动作”的代表作。
-

Q22 ◆ 如何设计 VLA 实现 zero-shot 泛化（开放题）

结构化答法，从三个层面：

1. **复用强 VLM backbone**：继承开放词汇语义和视觉常识 → 指令/物体语义泛化。
2. **数据多样性**：跨本体（Open X-Embodiment）、多场景、多任务训练 + co-fine-tuning 保住网络知识。
3. **动作表示与抽象**：用相对位姿/物体中心表示降低对绝对坐标的依赖；用 affordance / 语言子目标做中间抽象，提升组合泛化。
4. **(加分)**：引入人类视频学可迁移表征；用 chain-of-thought / 推理增强长程组合泛化（如 RT-H、ECoT）。

本模块自测（重点中的重点）**自测清单**

- ☐ 画出 VLA 架构图，说清三种输入
- ☐ 动作表示三条路线 + 各自优缺点（最高频）
- ☐ RT-2 一句话核心 + co-fine-tuning 作用
- ☐ OpenVLA 的双视觉编码器 + 数据集 + 结论
- ☐ action chunking 的 4 个好处
- ☐ 慢推理 vs 高频控制的 4 种协调方式
- ☐ flow matching 相比离散 token / 回归的优势

获取完整版

你正在阅读的是**免费试读版**，包含**完整题库总览（78 题全目录）**以及 M1 **基础概念**、M3 **VLA 模型**两个完整精讲模块。

完整版（v1.1 · 54 页）另含以下全部内容：

- **逐题精讲** M2、M4–M12：多模态 VLM、模仿学习与 Diffusion Policy、强化学习、世界模型、数据与 Sim2Real、3D 感知、规划控制、SOTA 论文、工程部署、开放题与项目面
- **深度补充 A · 数理基础**：attention、对比学习、DDPM、flow matching、CVAE、PPO、旋转表示
- **深度补充 B · PyTorch 代码**：Diffusion Policy、ACT、PPO、6D 旋转、极简 VLA 等核心实现

获取方式： 小红书主页「_____」 / 公众号「_____」回复 **具身** / 微信 _____